Introducción al Deep Learning con Python

Parte 2

MIGUEL ÁNGEL MARTÍNEZ DEL AMOR

DEPARTAMENTO CIENCIAS DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL

UNIVERSIDAD DE SEVILLA

About me

- **Miguel Ángel Martínez del Amor**
- Profesor Ayudante Doctor del Departamento de Ciencias de la Computación e Inteligencia Artificial

www.cs.us.es/~mdelamor

mdelamor@us.es

@miguelamda

miguelamda

Research Group on Natural Computing

DeepKnowledge

NVIDIA Deep Learning Institute

Índice

1. Introducción a la regularización.
2. Redes neuronales convolucionales.
3. Ejercicio 1: nuestra primera red neuronal convolucional con Keras.
4. Hardware para Deep Learning.
5. Algunas redes neuronales profundas y transferencia de aprendizaje.
6. Ejercicio 2: transfer learning con Keras.

Índice

Problemas de rendimiento

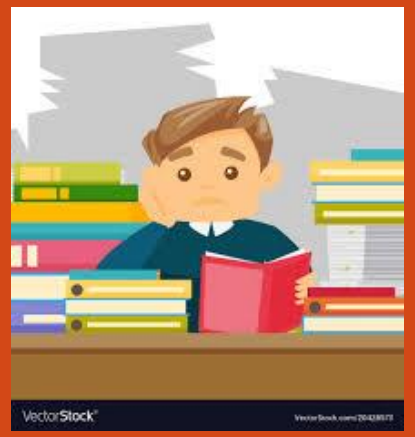	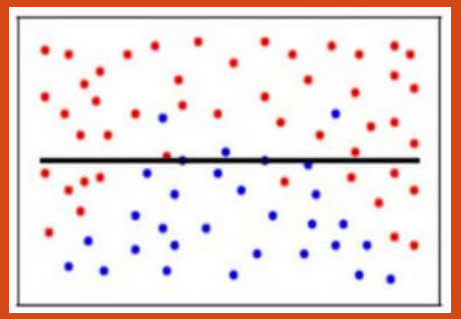	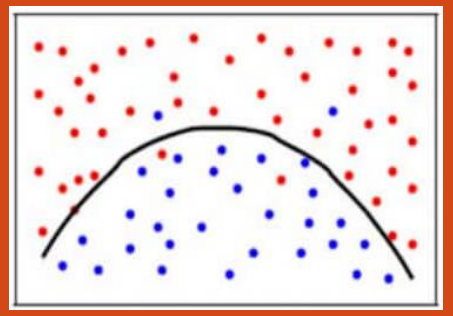	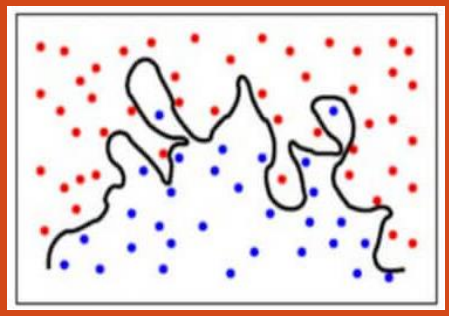
	Underfitting	Correcto	Overfitting
Entrenamiento	Malo	Bueno	Muy bueno
Test	Malo	Bueno	Malo

Problemas de rendimiento

Necesidad de regularización

Técnicas para atacar el sobreajuste (overfitting) son:

- **Dataset:**
  - **Aumentar** la cantidad de datos
  - **Simplificar** los datos, reduciendo el número de características:
    - Manualmente
    - Técnicas de reducción de dimensionalidad (PCA, t-SNE, …)
- **Modelo (regularización):**
  - Mantenemos todas las características de los datos
  - Reducir los valores de los parámetros del modelo
  - Funciona bien cuando tenemos muchas características y todas aportan un poco a predecir

Early stopping

Partir el conjunto en 3 subconjuntos:

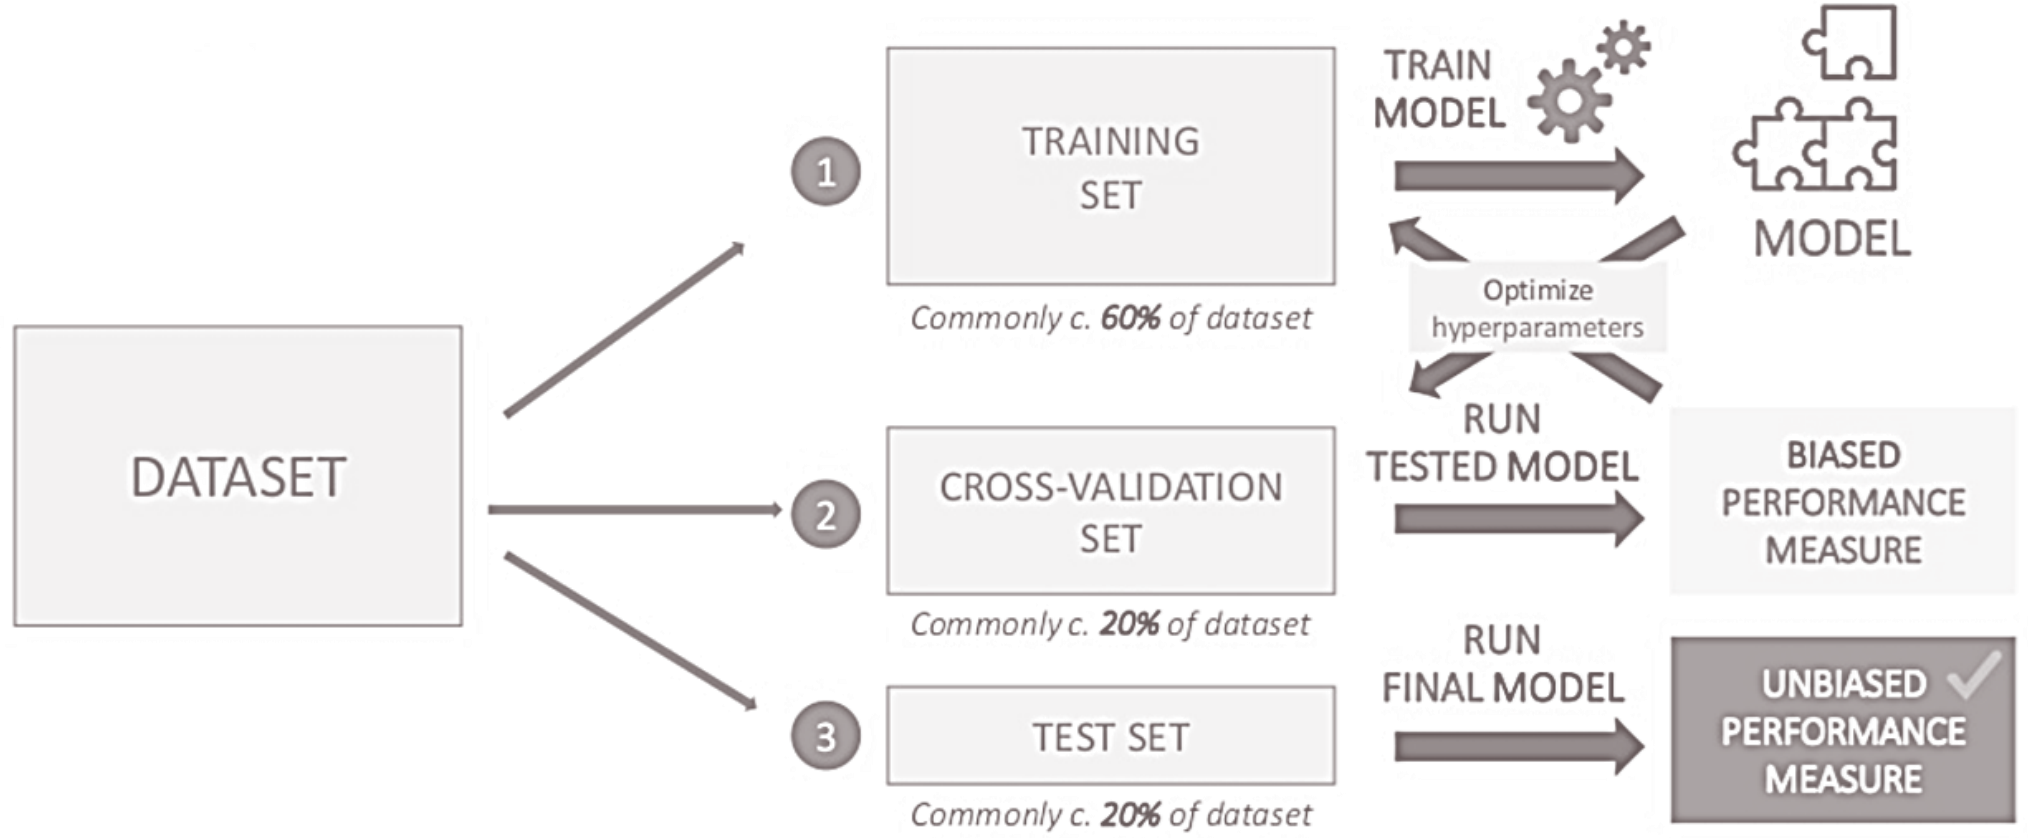

Early stopping

Idea: detener el entrenamiento cuando el error cometido sobre el conjunto de validación crece.

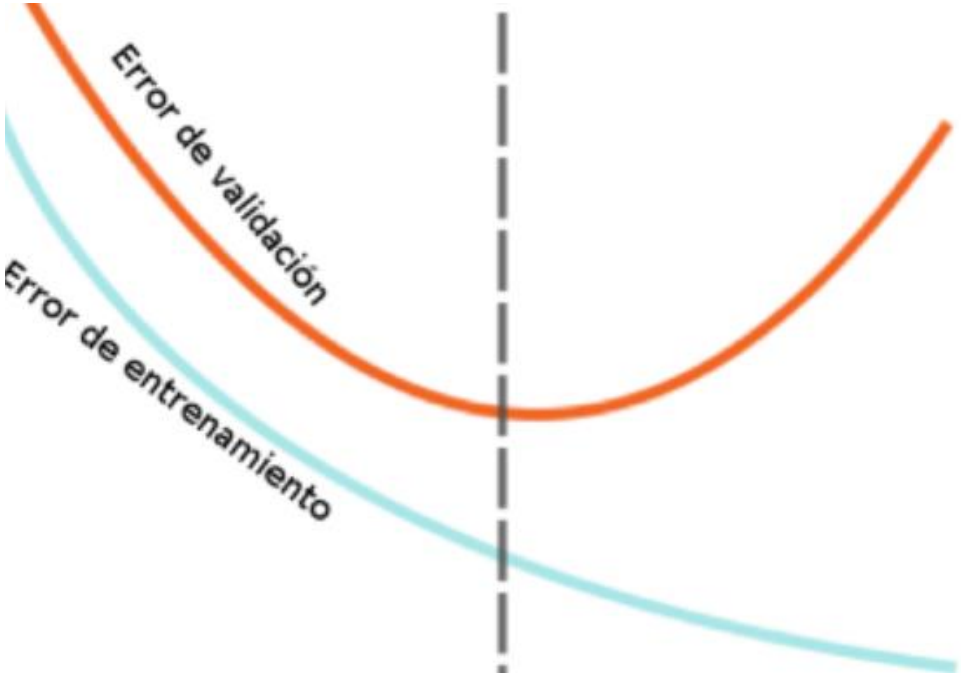

Dropout

Idea: aleatoriamente **poner a cero** algunas neuronas en la propagación hacia adelante **Hiperparámetro**: **p**

- Probabilidad de poner a cero

[Srivastava et al 2014]

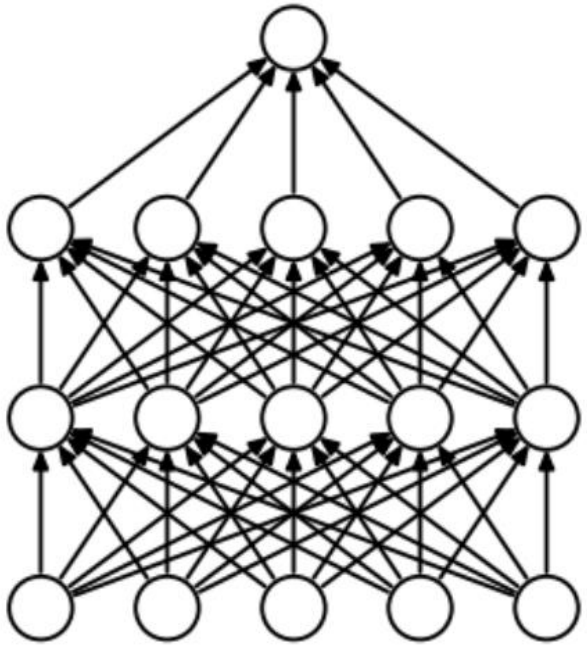

(a) Standard Neural Net

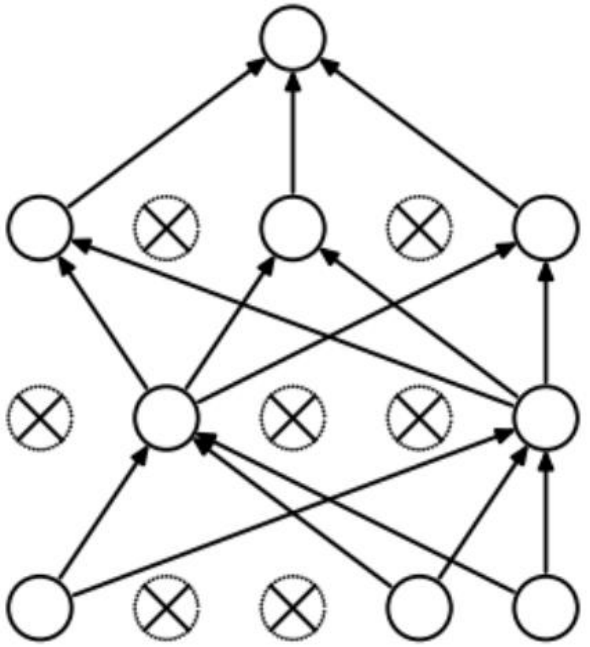

(b) After applying dropout.

Dropout

Fuerza a la red tener una representación más redundante

- La red encuentra otros “caminos” dentro de la red para llegar a la misma conclusión

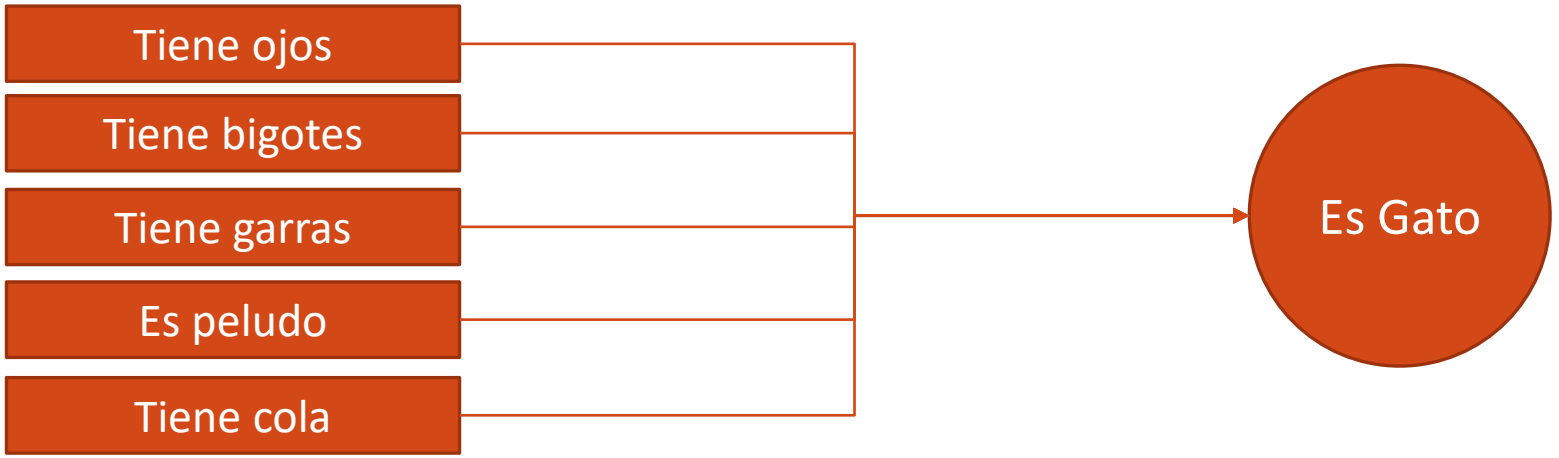

Dropout

Fuerza a la red tener una representación más redundante

- La red encuentra otros “caminos” dentro de la red para llegar a la misma conclusión

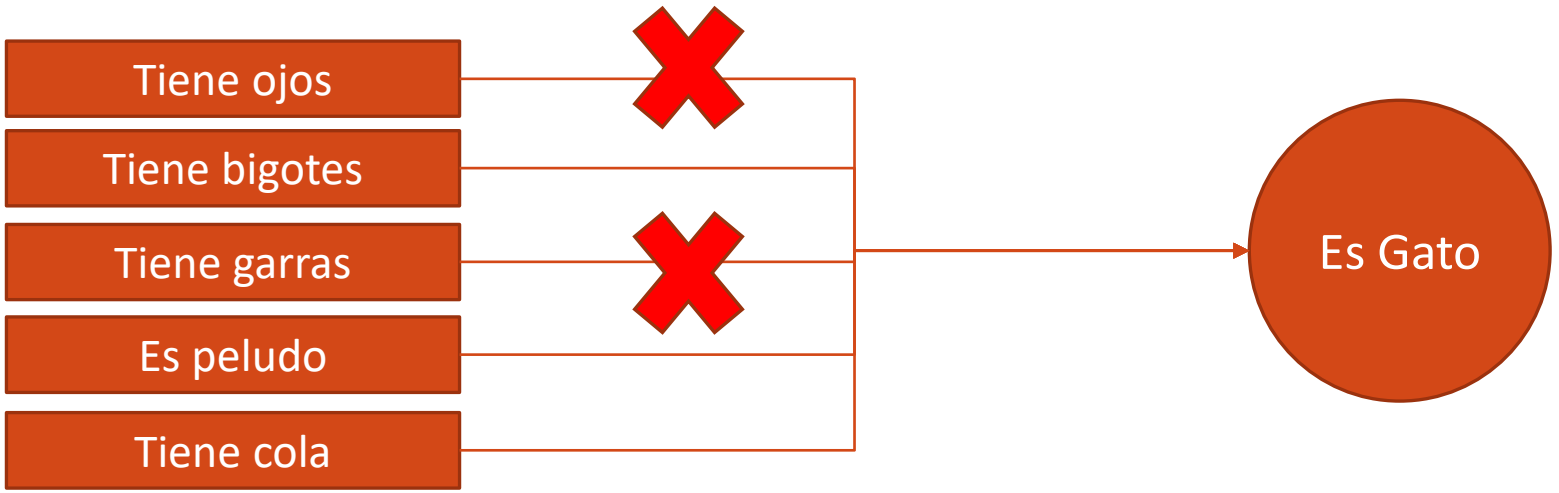

Aumentado de datos

Transformaciones típicas: mirroring, cropping

Data augmentation

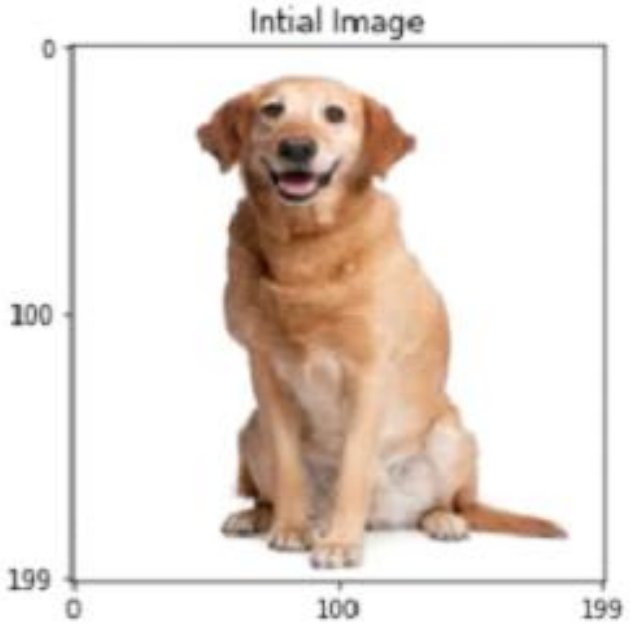

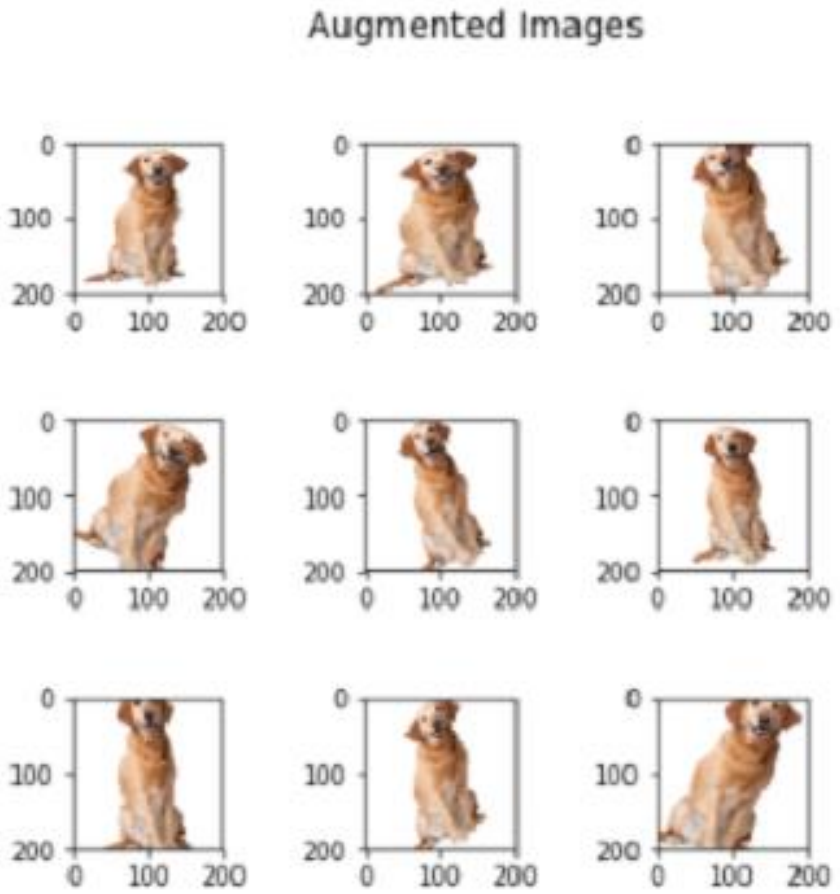

Índice

1. Introducción a la regularización.
2. Redes neuronales convolucionales.
3. Ejercicio 1: nuestra primera red neuronal convolucional con Keras.
4. Hardware para Deep Learning.
5. Algunas redes neuronales profundas y transferencia de aprendizaje.
6. Ejercicio 2: transfer learning con Keras.

El origen

El experimento Hubel & Wiesel 1959, 1962, 1968

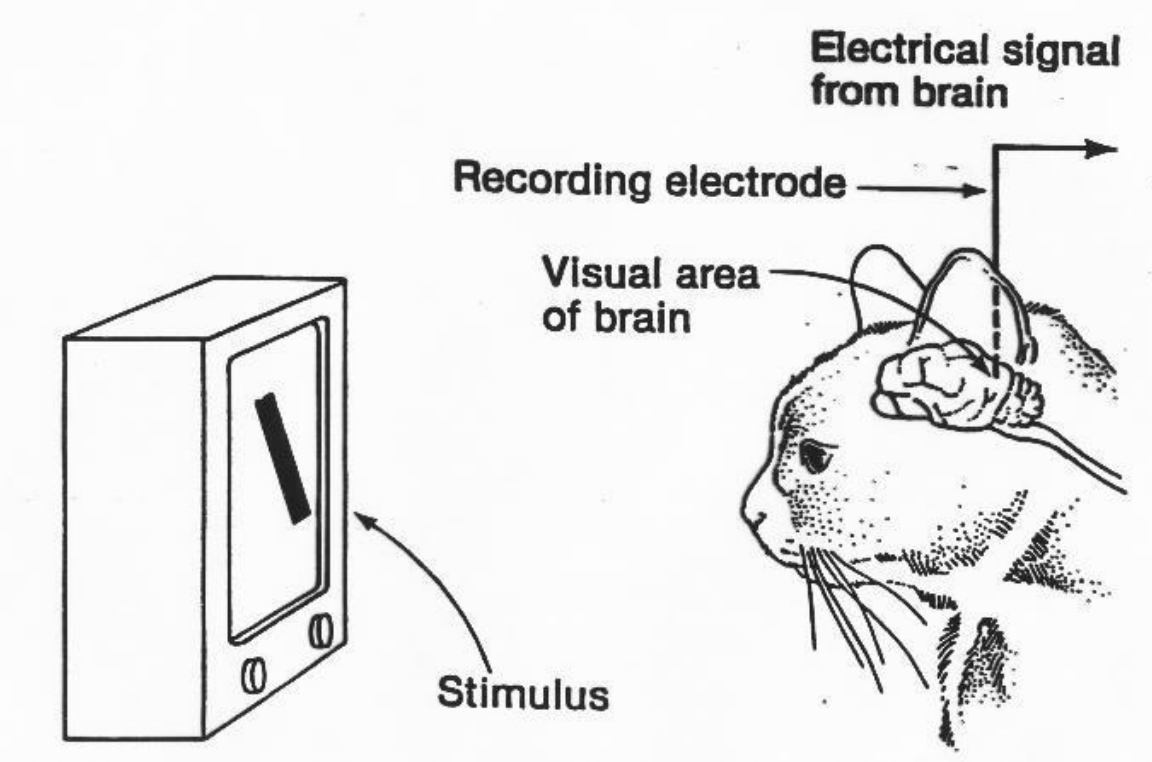

El origen

El experimento Hubel & Wiesel 1959, 1962, 1968

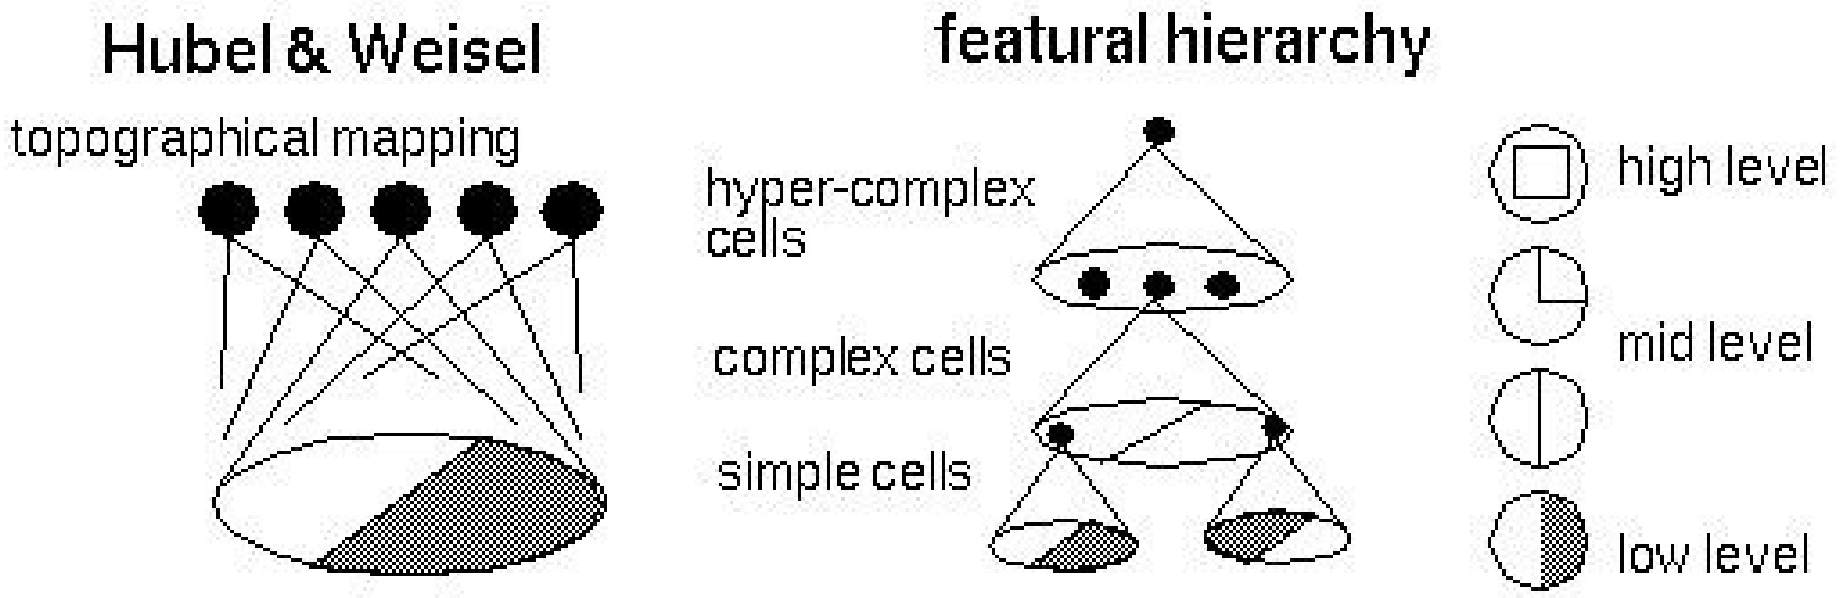

Primera red convolucional

Gradient-based learning applied to document recognition [LeCun, Bottou, Bengio, Haffner 1998]

- Reconocimiento de caracteres escritos a mano.
- Ya primeros experimentos en 1993.
- Entrenado con **backpropagation**.

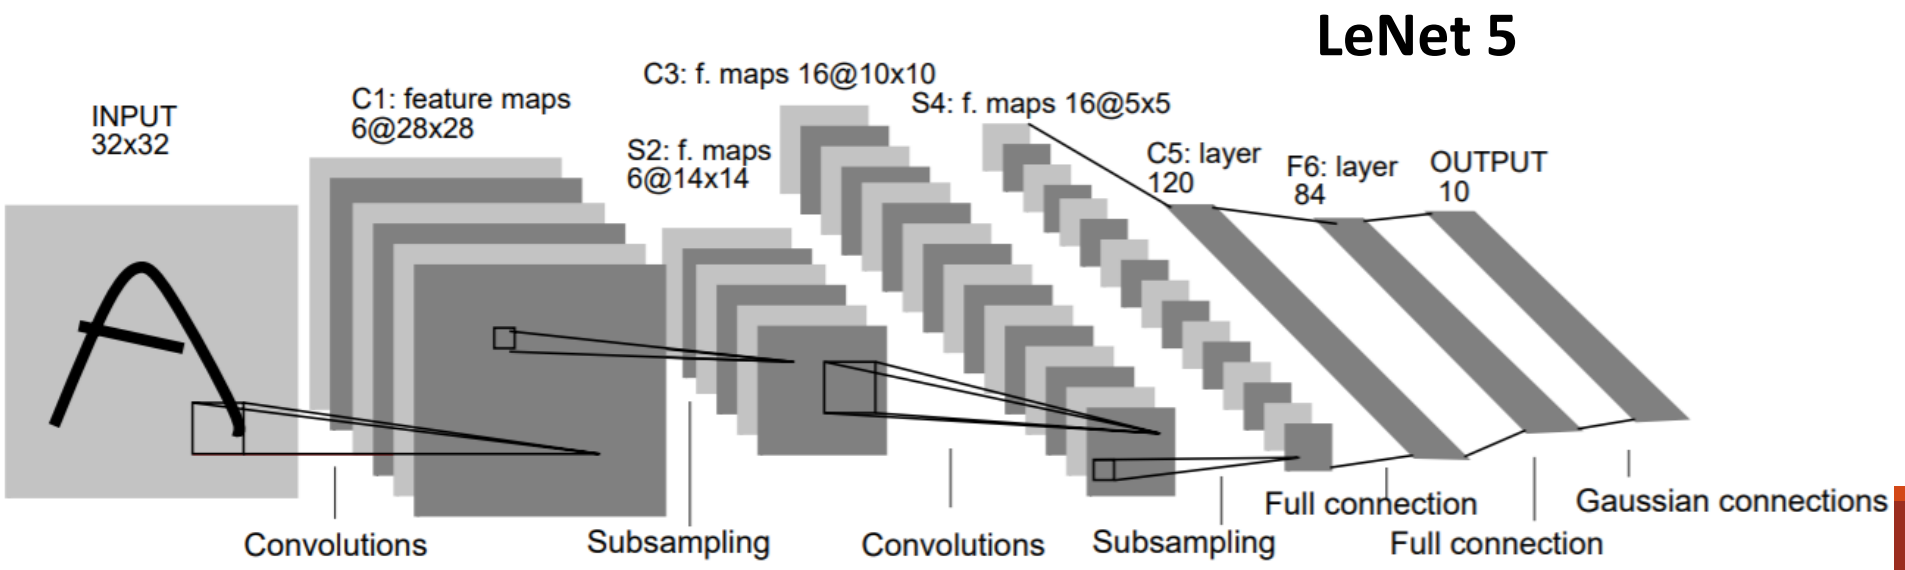

El gran salto

***ImageNet** Classification with Deep Convolutional Neural Networks* [Krizhevsky, Sutskever, Hinton 2012]. **Diferencias**:

- Entrenado sobre ImageNet (10^6 imágenes, 1000 categorías)
- Usa ReLU (LeNet 5 usa tanh) y dropout
- Más profundo
- Uso de GPUs (6 días)

AlexNet

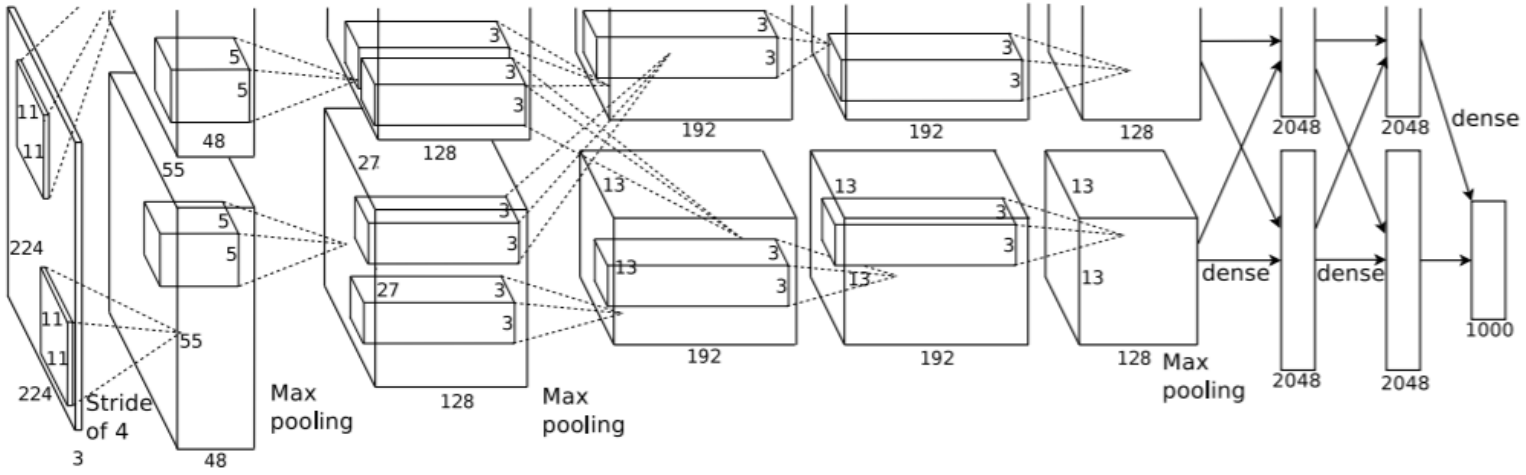

IMAGENET

Desde entonces…

Tendencia

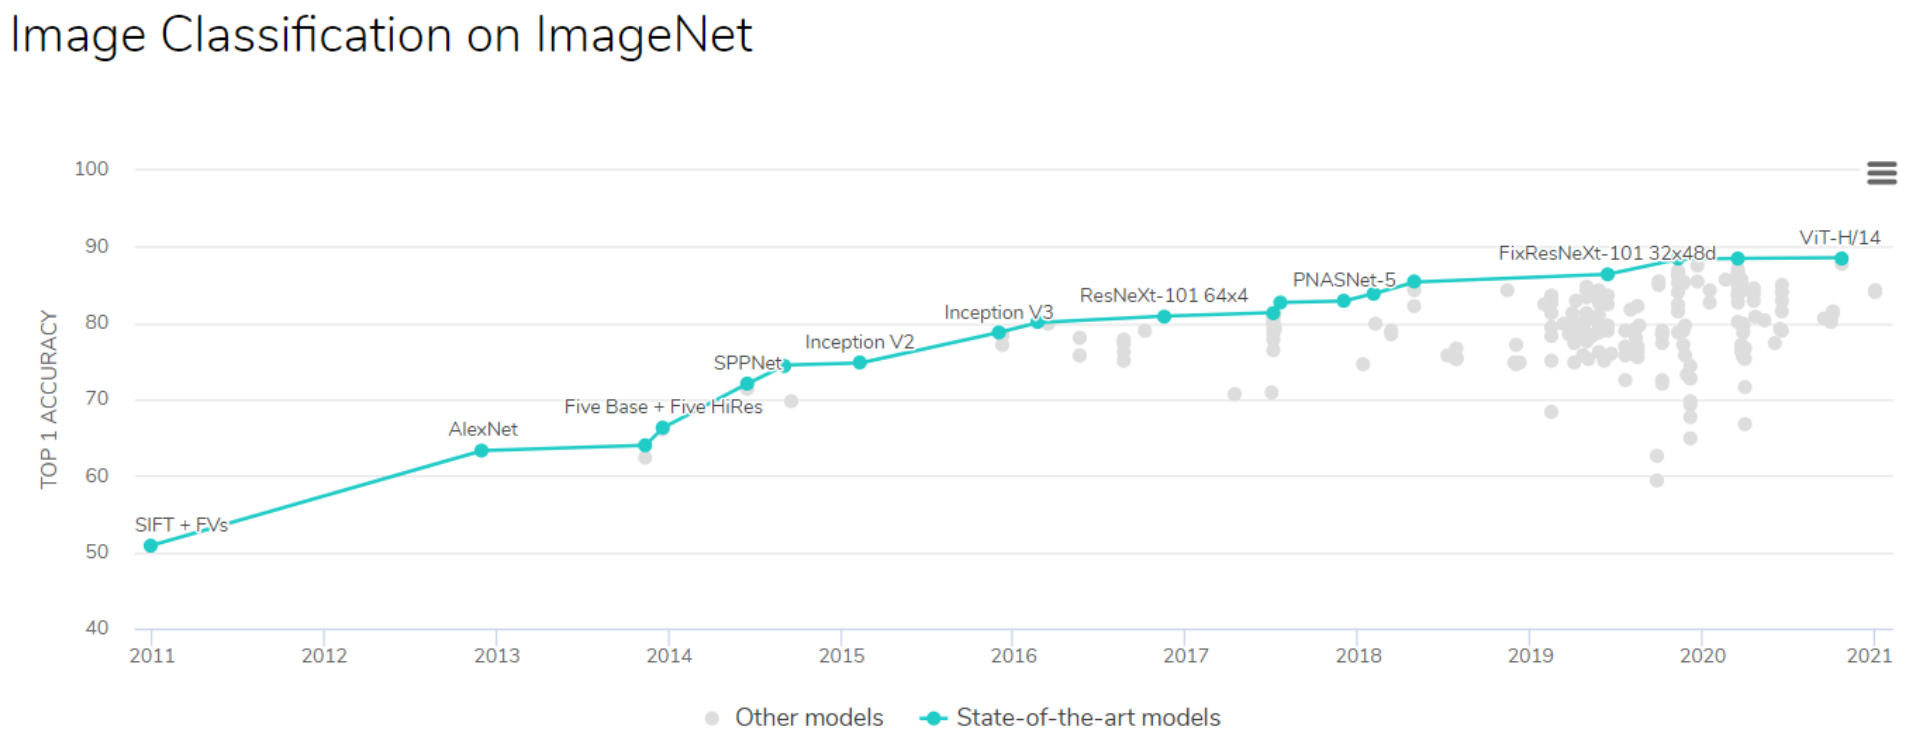

https://paperswithcode.com/sota/image-classification-on-imagenet

Convolución

- Operación básica:
  - Multiplicación elemento a elemento
  - Suma de las multiplicaciones
- Para cada posible encaje del **kernel (filtro)** en la matriz de entrada:
  - Aplicar operación de convolución
  - Anotar el valor de salida en la matriz resultado
- Es **derivable** para propagación de gradientes.

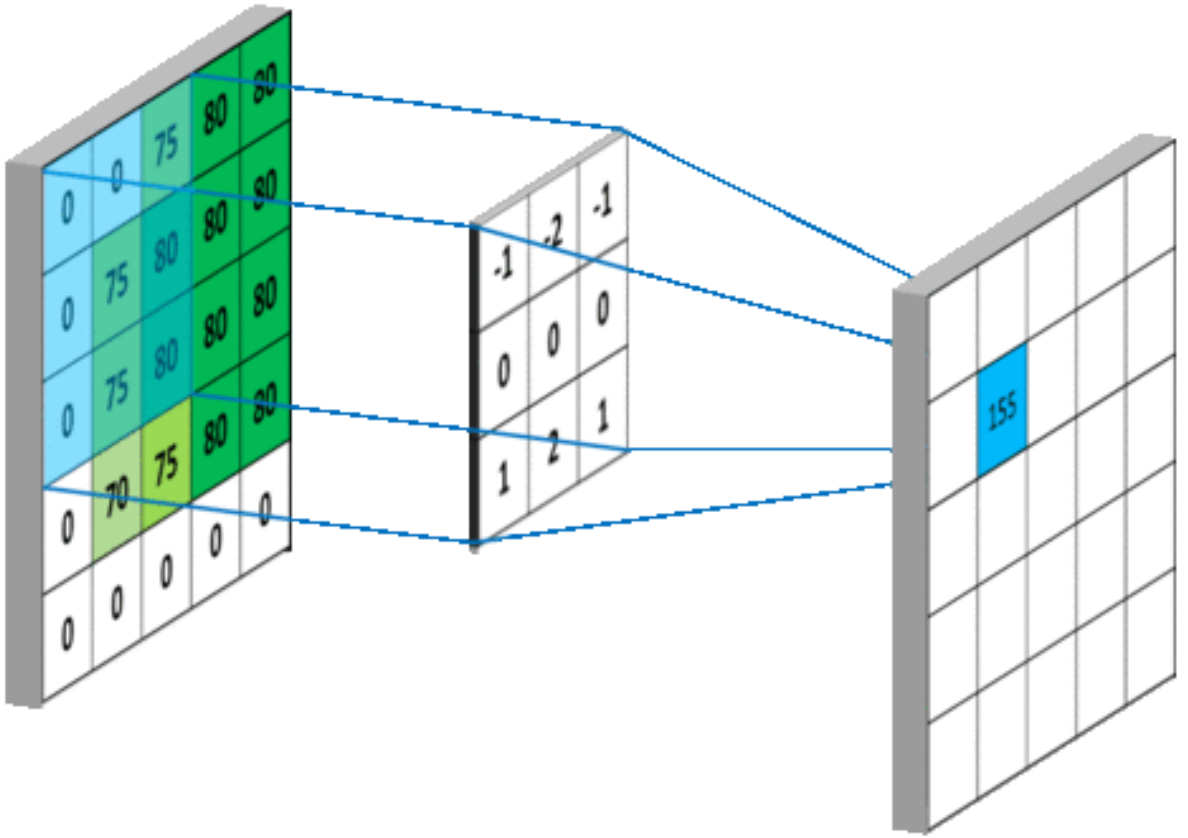

https://analyticsindiamag.com/convolutional-neural-network-image-classification-overview/

Convolución

Ejemplos de convolución sobre imágenes

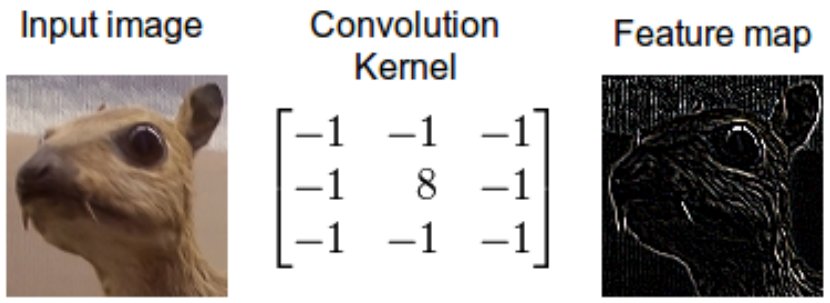

Detección bordes

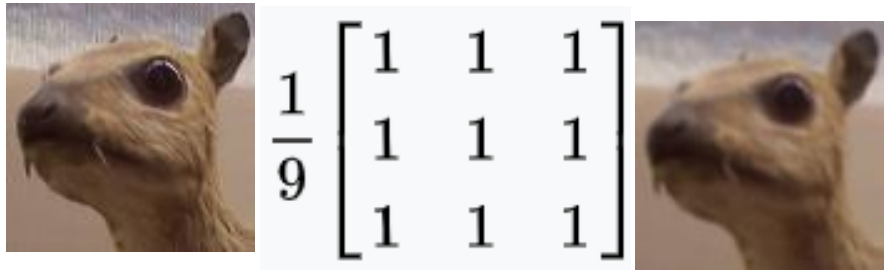

Difuminado (Blur)

Pooling (subsampling/downsampling)

- Capa que **redimensiona** espacialmente la representación
- Es común insertarla periódicamente entre capas convolutivas
- **Operaciones** típicas: MAX, AVG, SUM, L2, …
- Es **derivable** para propagación de gradientes.

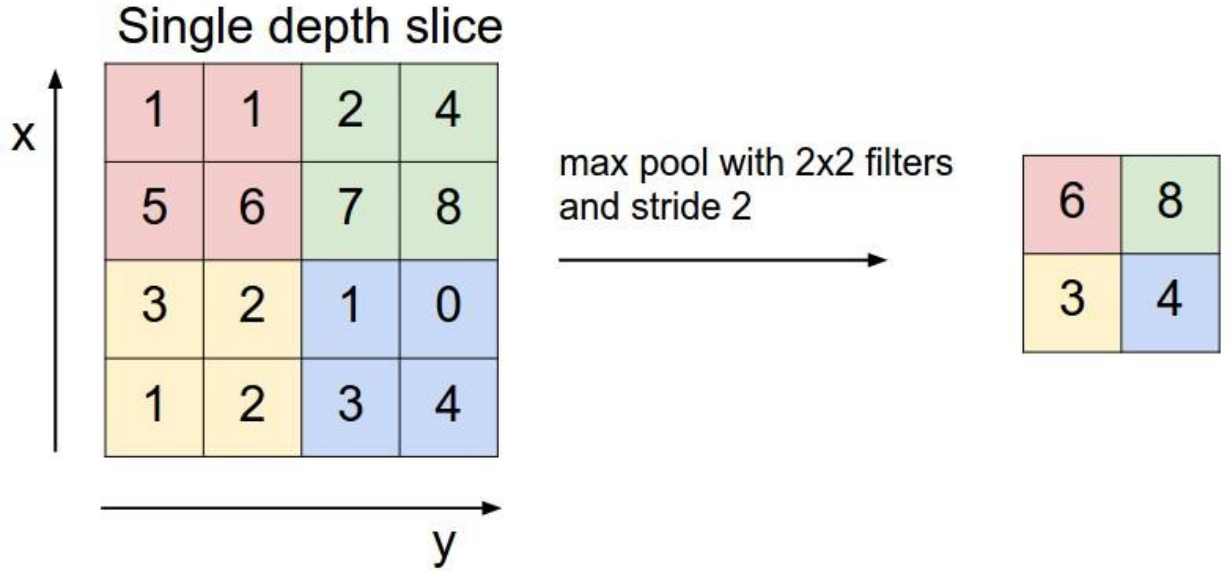

Interpretando redes convolucionales

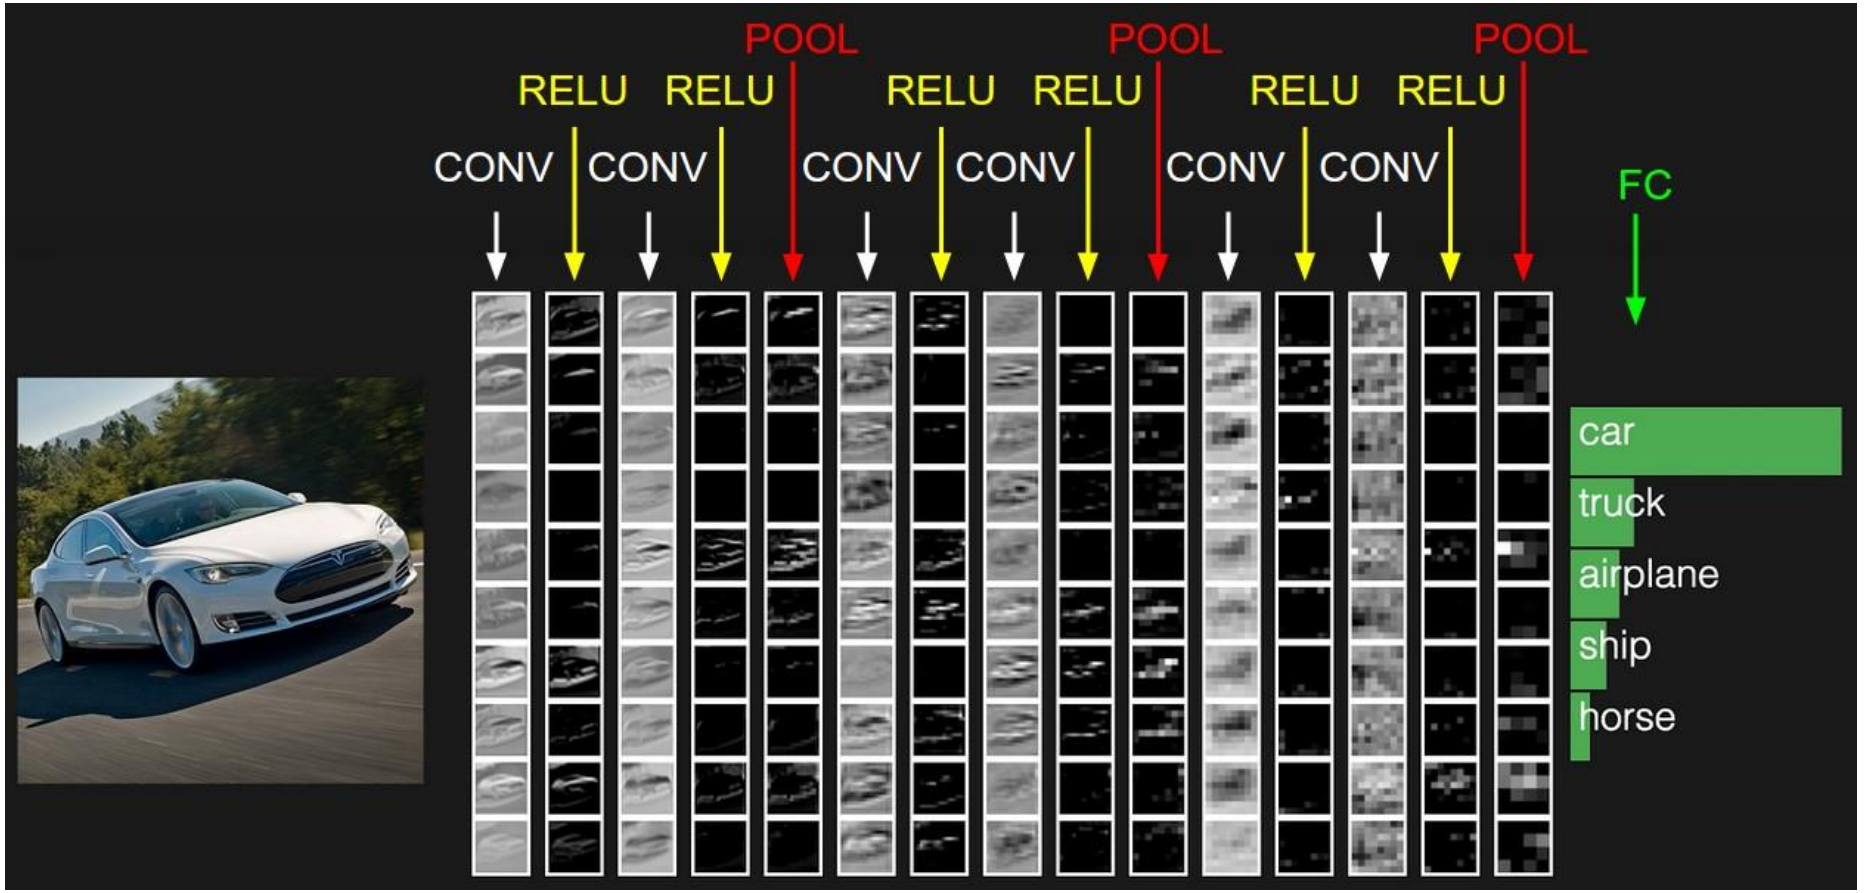

Interpretando redes convolucionales

Visualización de los filtros aprendidos por una red (ver aquí).

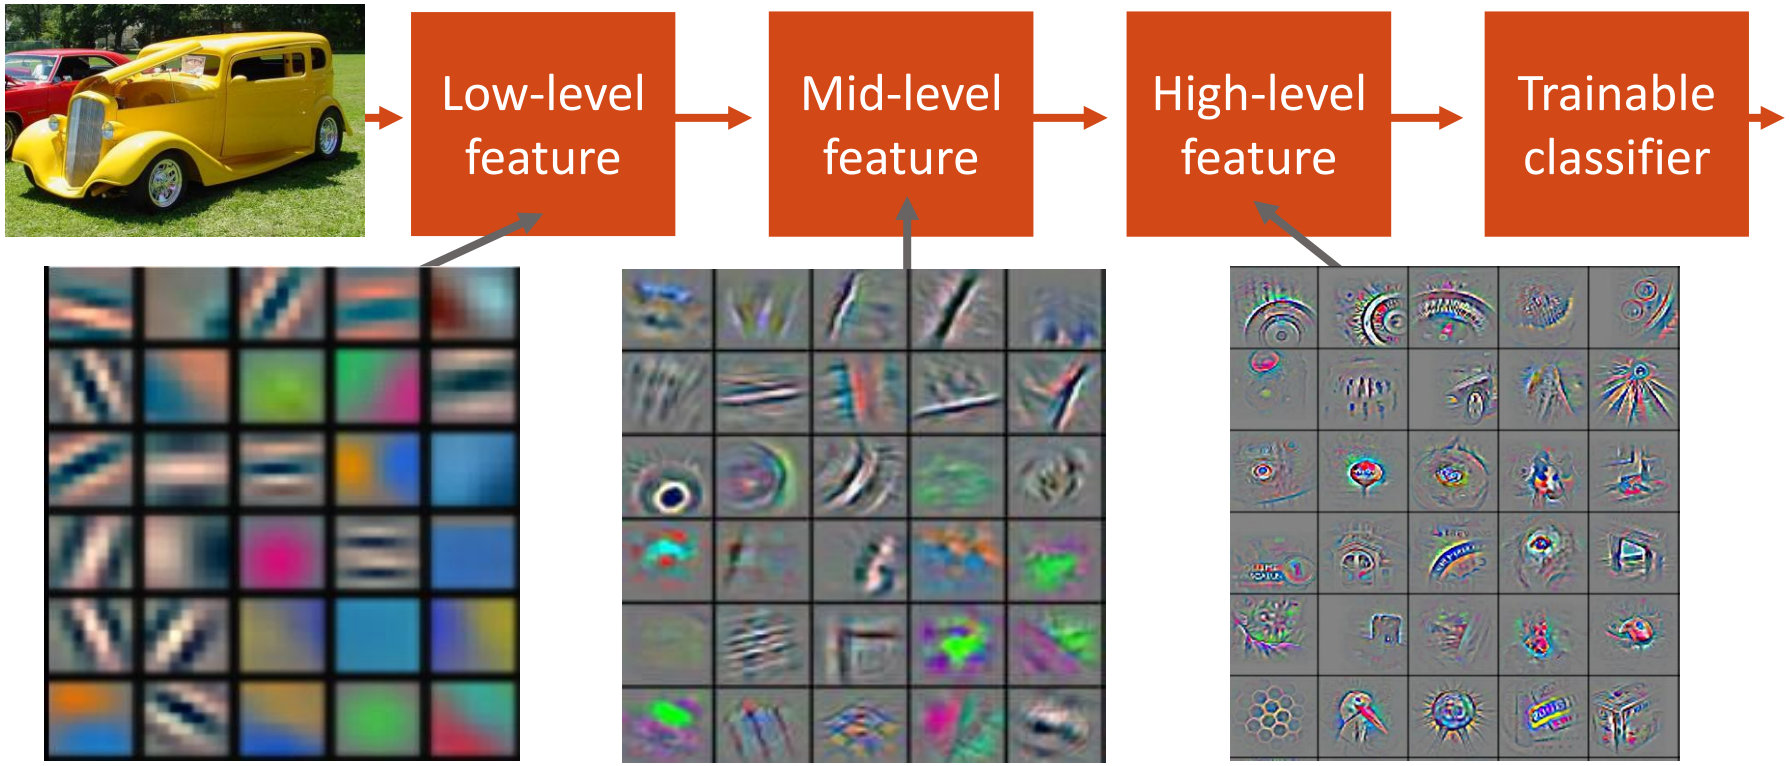

Índice

1. Introducción a la regularización.
2. Redes neuronales convolucionales.
3. Ejercicio 1: nuestra primera red neuronal convolucional con Keras.
4. Hardware para Deep Learning.
5. Algunas redes neuronales profundas y transferencia de aprendizaje.
6. Ejercicio 2: transfer learning con Keras.

Índice

1. Introducción a la regularización.
2. Redes neuronales convolucionales.
3. Ejercicio 1: nuestra primera red neuronal convolucional con Keras.
4. Hardware para Deep Learning.
5. Algunas redes neuronales profundas y transferencia de aprendizaje.
6. Ejercicio 2: transfer learning con Keras.

La trinidad del Deep Learning

Big Data Availability

facebook 350 millions images uploaded per day

Walmart 2.5 Petabytes of customer data hourly

YouTube 300 hours of video uploaded every minute

New ML Techniques

GPU Acceleration

Hardware paralelo: GPUs

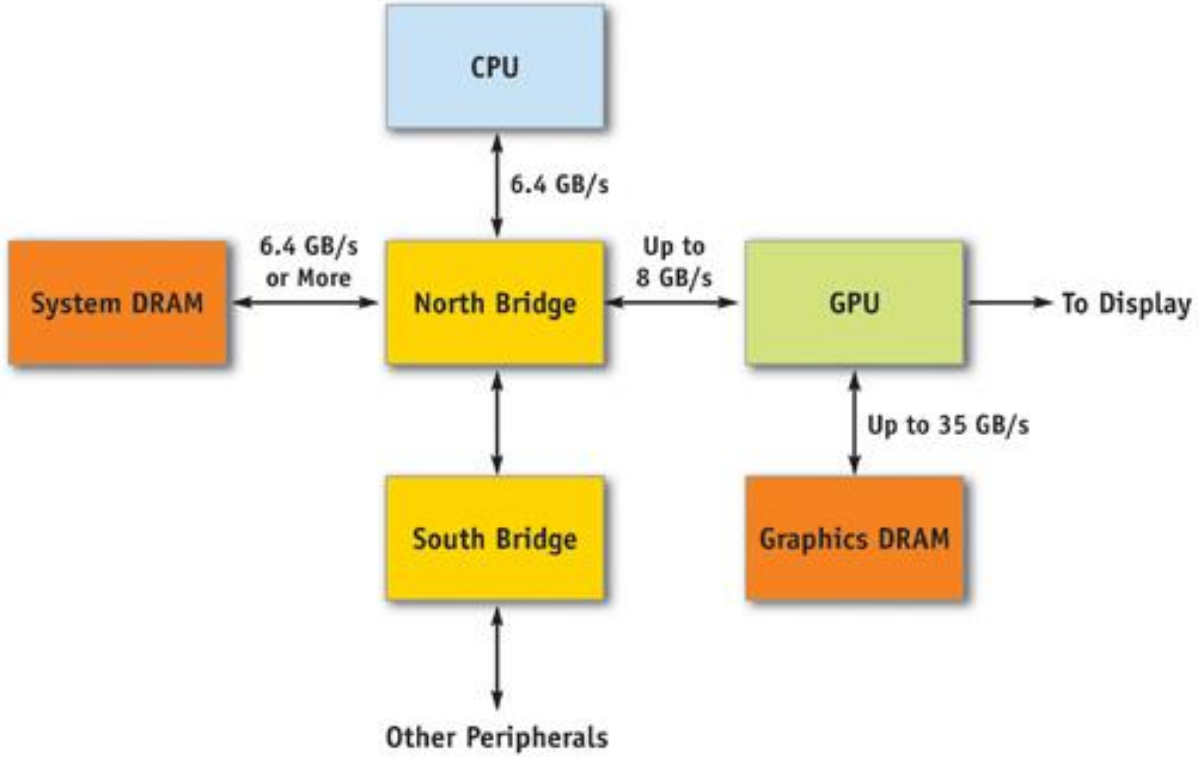

Hardware paralelo: GPUs

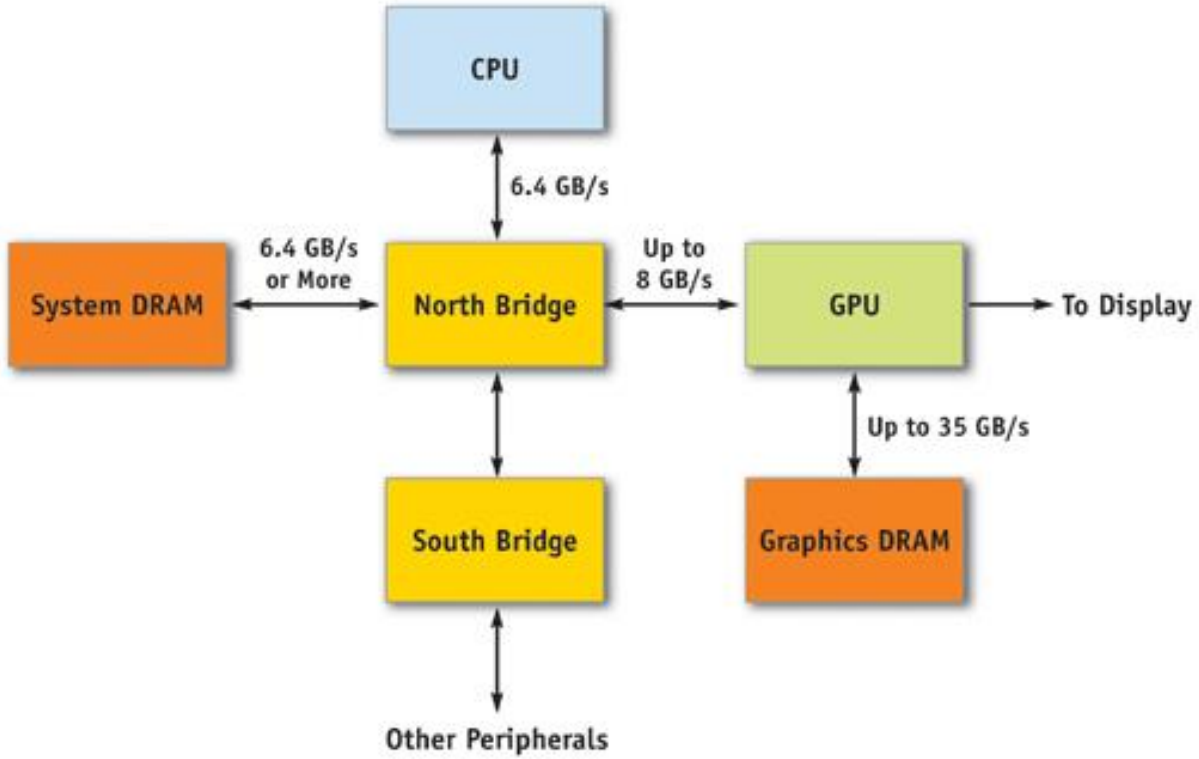

Hardware paralelo: GPUs

GTC2009: Cazadores de mitos mostrando CPU vs GPU

Hardware paralelo: GPUs

- **GPU** = Graphics Processing Unit (núcleo tarjeta gráfica).
- Con el tiempo este procesador ha evolucionado y hoy en día se puede usar para cómputo paralelo, incluyendo del orden de cientos a miles de núcleos.
- **CUDA cores (Streaming Processors)**: Los núcleos son más básicos que los de una CPU, pero son muchos más!
- Muy buenos con cálculo matricial.
- Ahora incluyen núcleos especiales para Deep Learning: **Tensor cores**

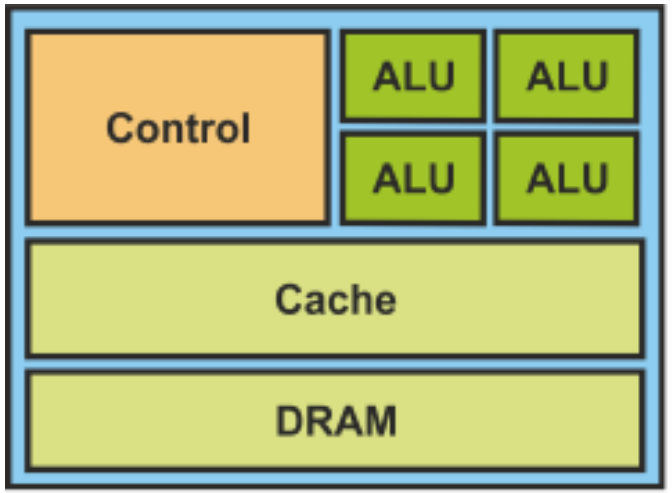

CPU

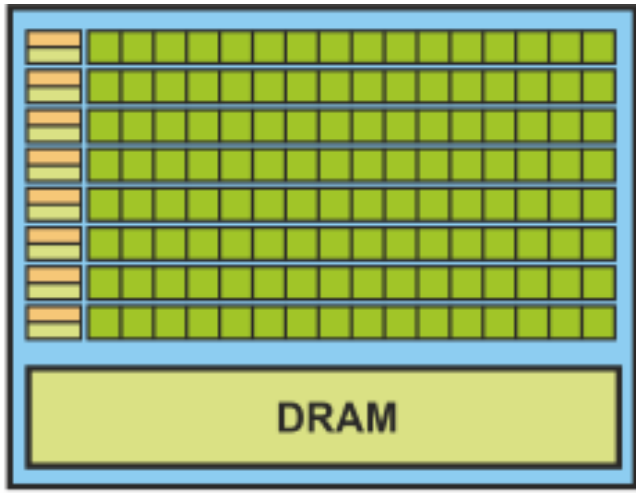

GPU

Hardware paralelo: GPUs

- Librerías para programar GPUs:
  - ***CUDA*** (de NVIDIA)
  - ***OpenCL*** (Chronos → NVIDIA, AMD, Intel…), ahora ***SYCL***
  - ***ROCm*** (de AMD), ***HIP*** para traducir CUDA-like code
- **NVIDIA** invirtió en Deep Learning desde el principio, y ahora ofrece un **mayor soporte** (todos los frameworks soportan de forma nativa GPUs mediante CUDA): CuDNN, CuBLAS, …
- OpenCL y ROCm (**AMD**) es soportado de manera **experimental** por algunos frameworks.

OpenCL

Hardware paralelo: TPUs

TPU = Tensor Processing Unit

Chip introducido por Google en 2016 para Deep Learning.

Especializados para acelerar cálculo tensorial (algebra lineal).

Uso desde **TensorFlow y PyTorch**

En fase **beta**:

- De Gigas a Tera Bytes de memoria.
- De cientos a miles de núcleos.

Disponible en Cloud: 8$/hora

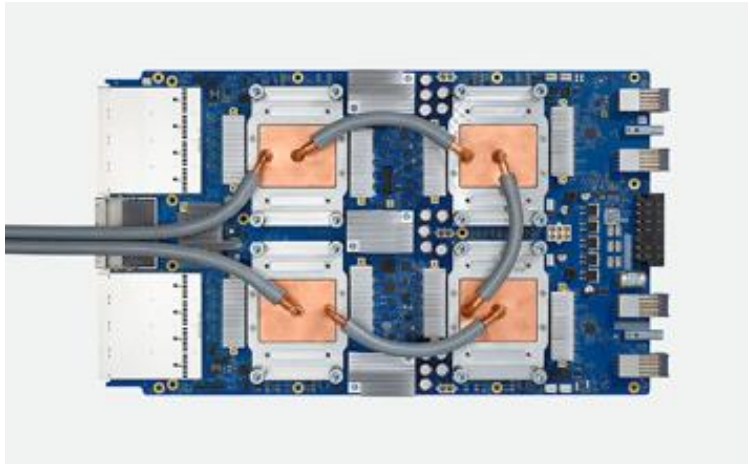

Índice

1. Introducción a la regularización.
2. Redes neuronales convolucionales.
3. Ejercicio 1: nuestra primera red neuronal convolucional con Keras.
4. Hardware para Deep Learning.
5. Algunas redes neuronales profundas y transferencia de aprendizaje.
6. Ejercicio 2: transfer learning con Keras.

Clasificación de objetos

Tareas en **visión por computador**

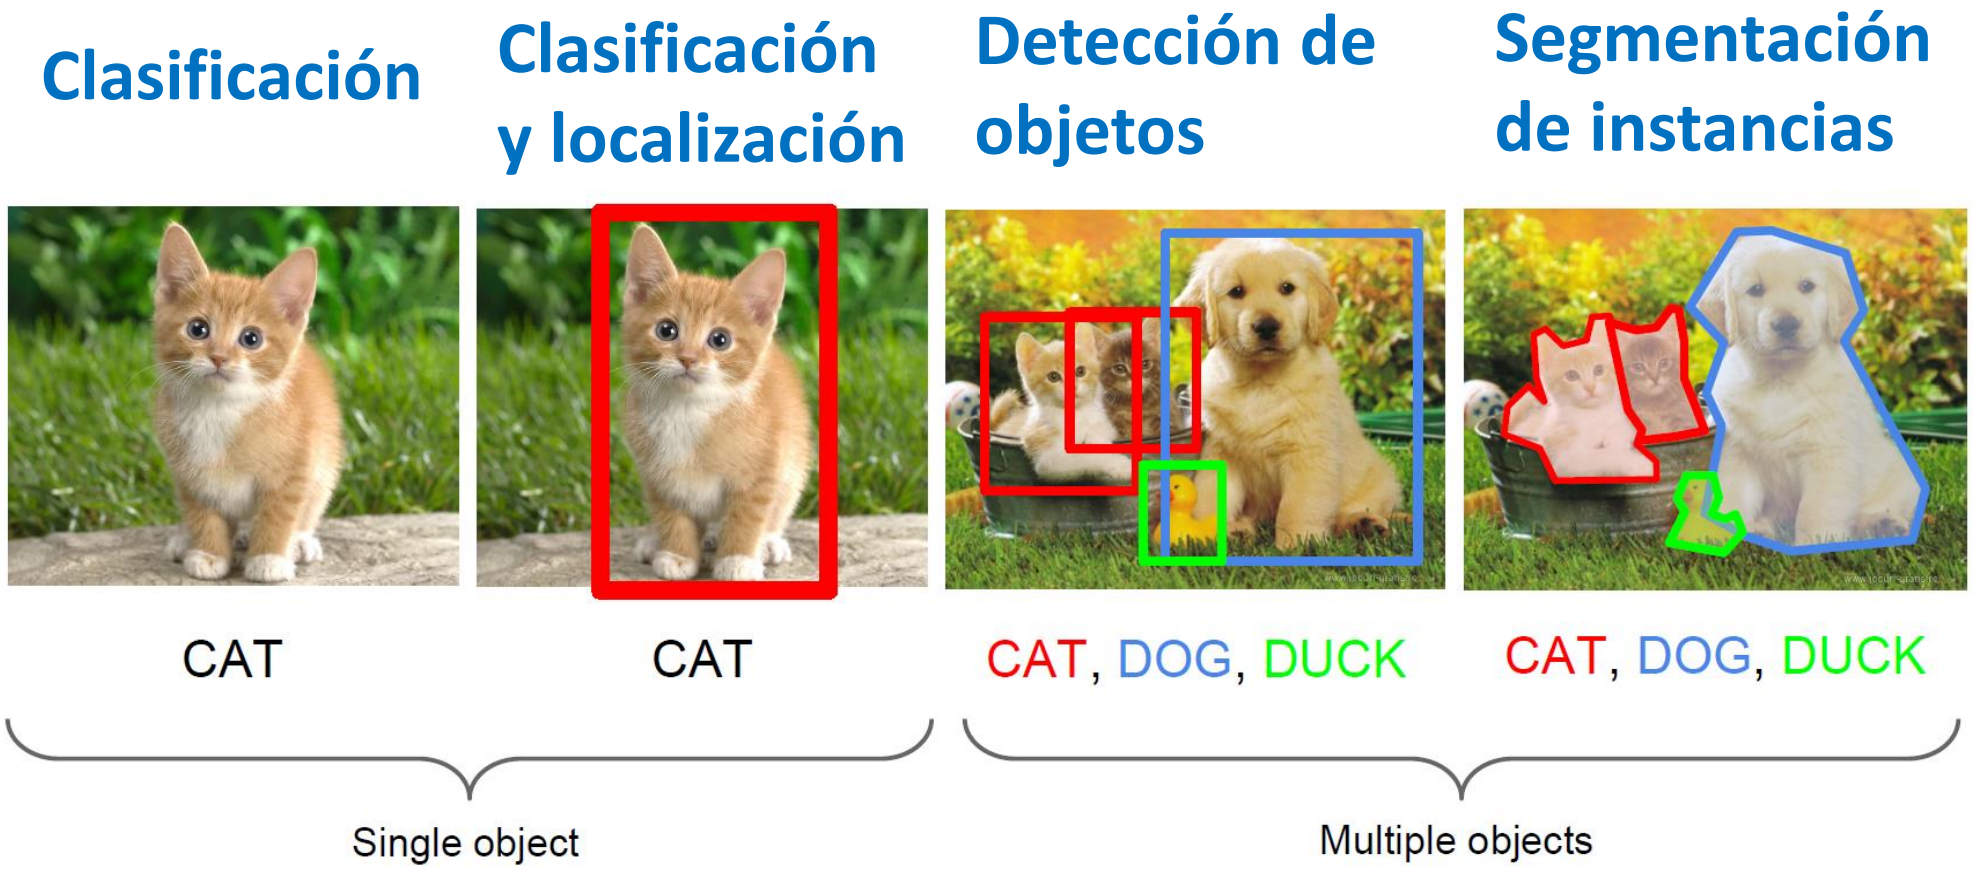

Clasificación de objetos

Tareas en **visión por computador**

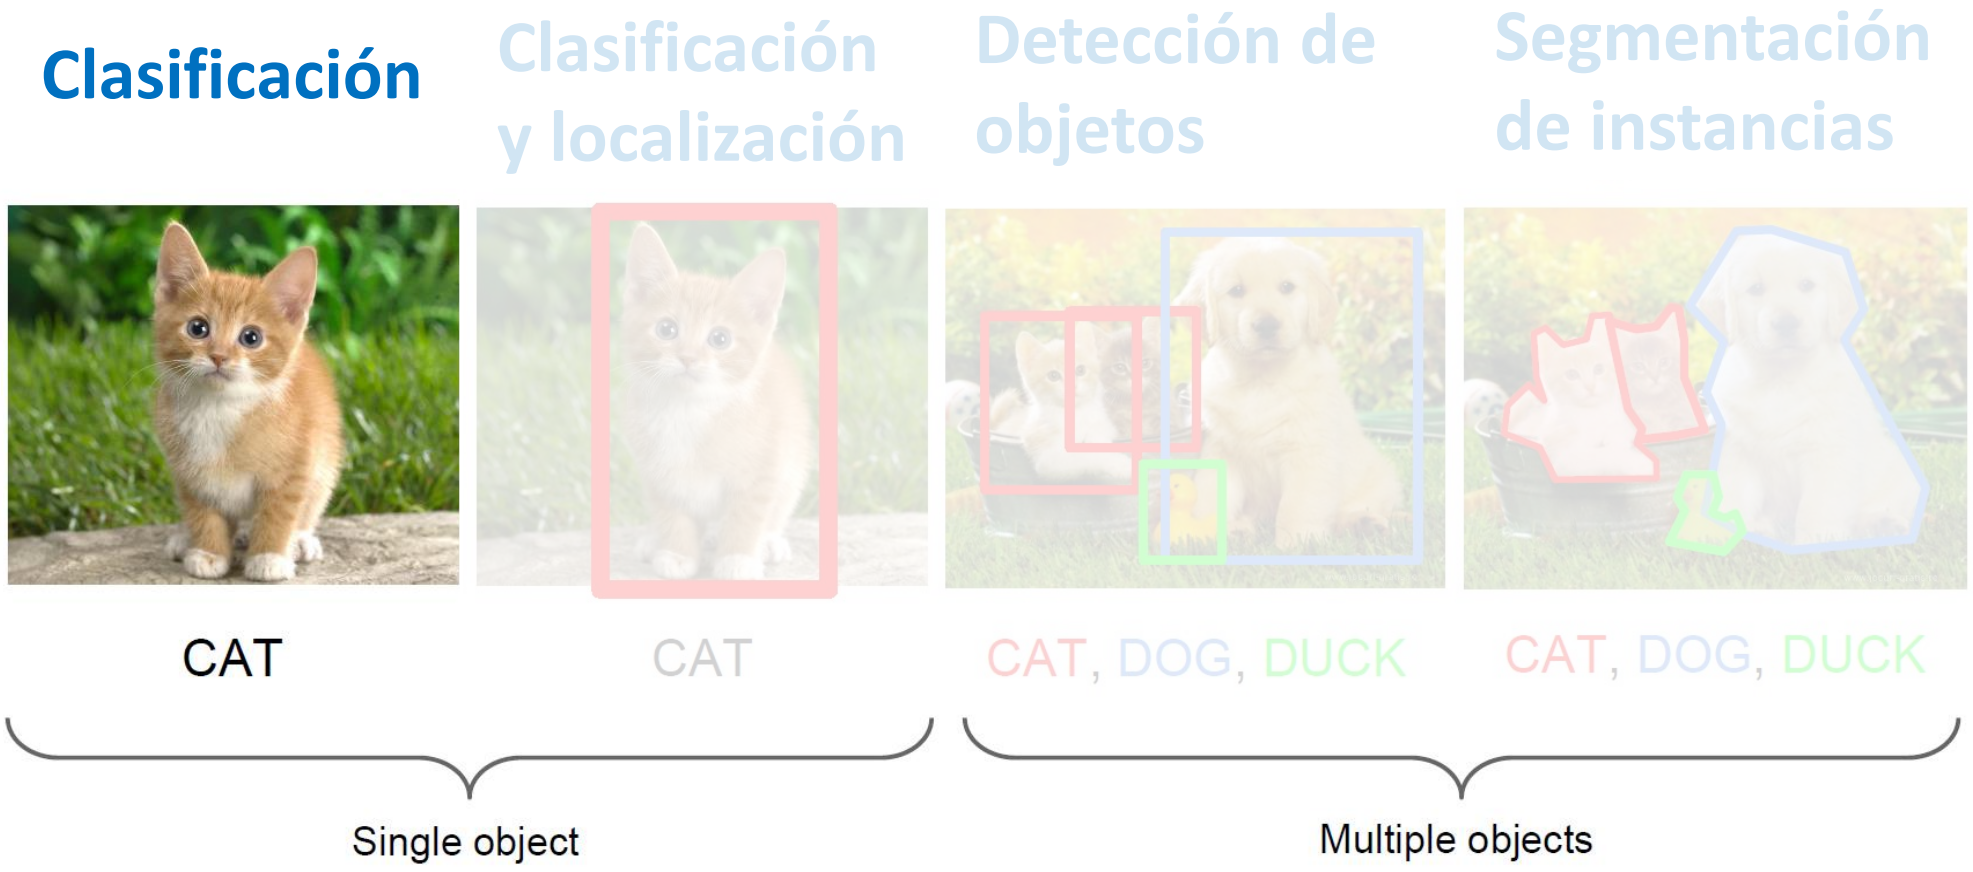

VGG

- Versión **VGG16** y **VGG19** (con 16 y 19 capas)
- Convolución 3x3 (con efectividad de 5x5)
- Pooling 2x2

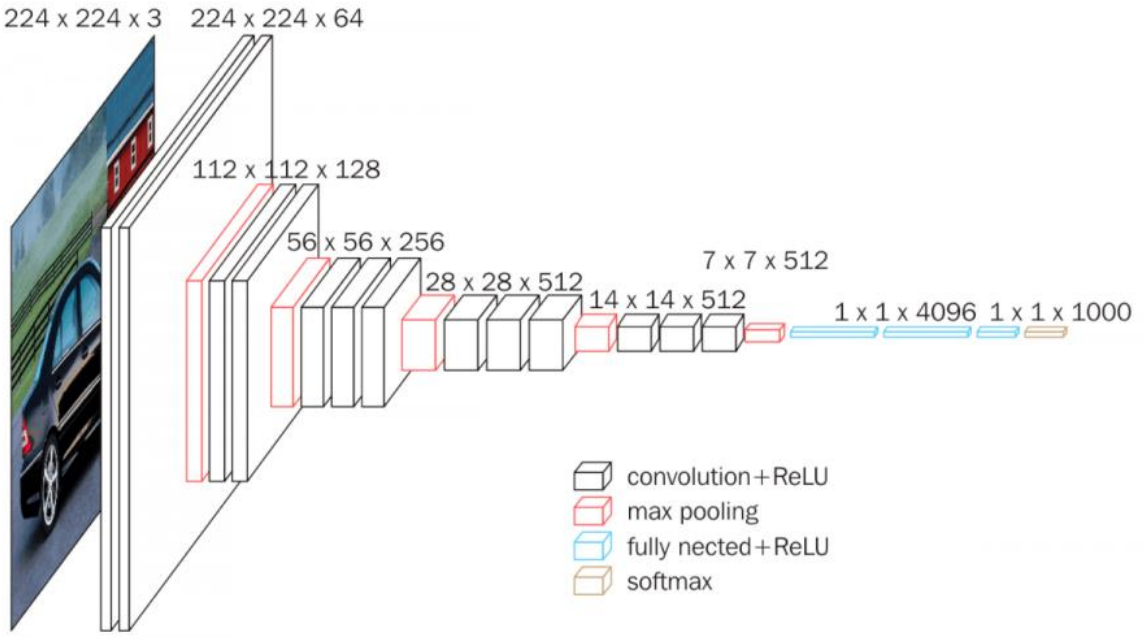

ResNet

- Desarrollado en Microsoft Research en 2015
- Variantes: **ResNet20**, **ResNet32**, **ResNet56**…

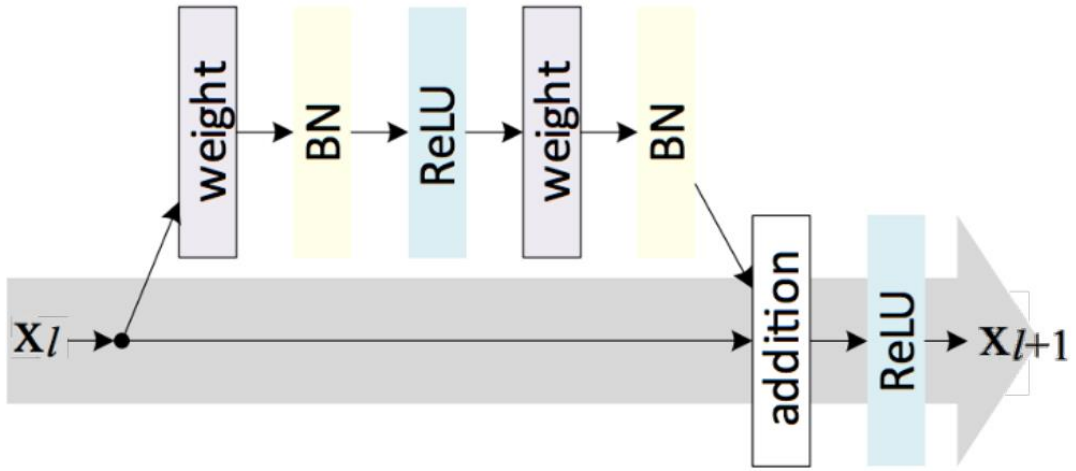

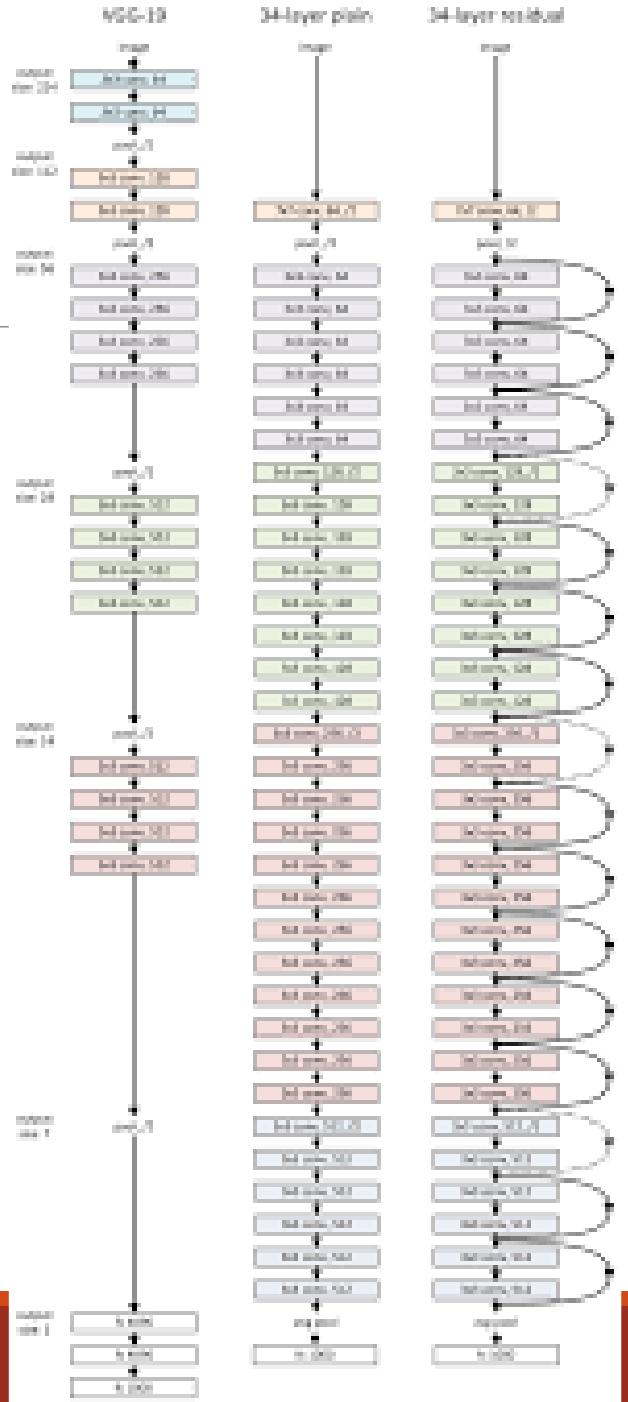

Inception

- Desarrollado en Google
- Versiones: GoogLeNet (Inception v1), v2, v3, v4…

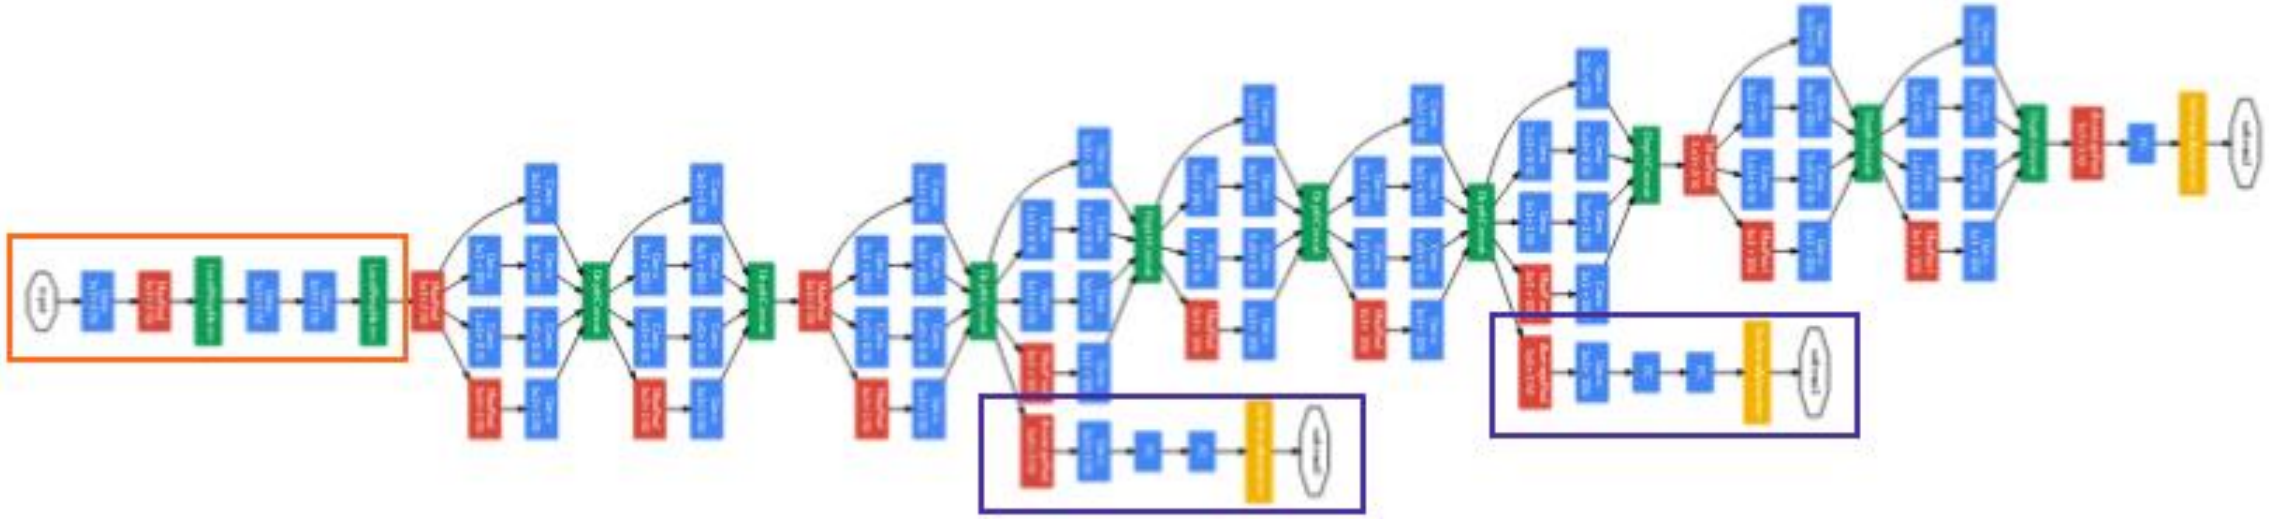

Comparativa

Year	CNN	Developed by	Place	Top-5 error rate	No. of parameters
1998	LeNet(8)	Yann LeCun et al			60 thousand
2012	AlexNet(7)	Alex Krizhevsky, Geoffrey Hinton, Ilya Sutskever	1st	15.3%	60 million
2013	ZFNet()	Matthew Zeiler and Rob Fergus	1st	14.8%	
2014	GoogLeNet(19)	Google	1st	6.67%	4 million
2014	VGG Net(16)	Simonyan, Zisserman	2nd	7.3%	138 million
2015	ResNet(152)	Kaiming He	1st	3.6%	

Detección de objetos

Tareas en **visión por computador**

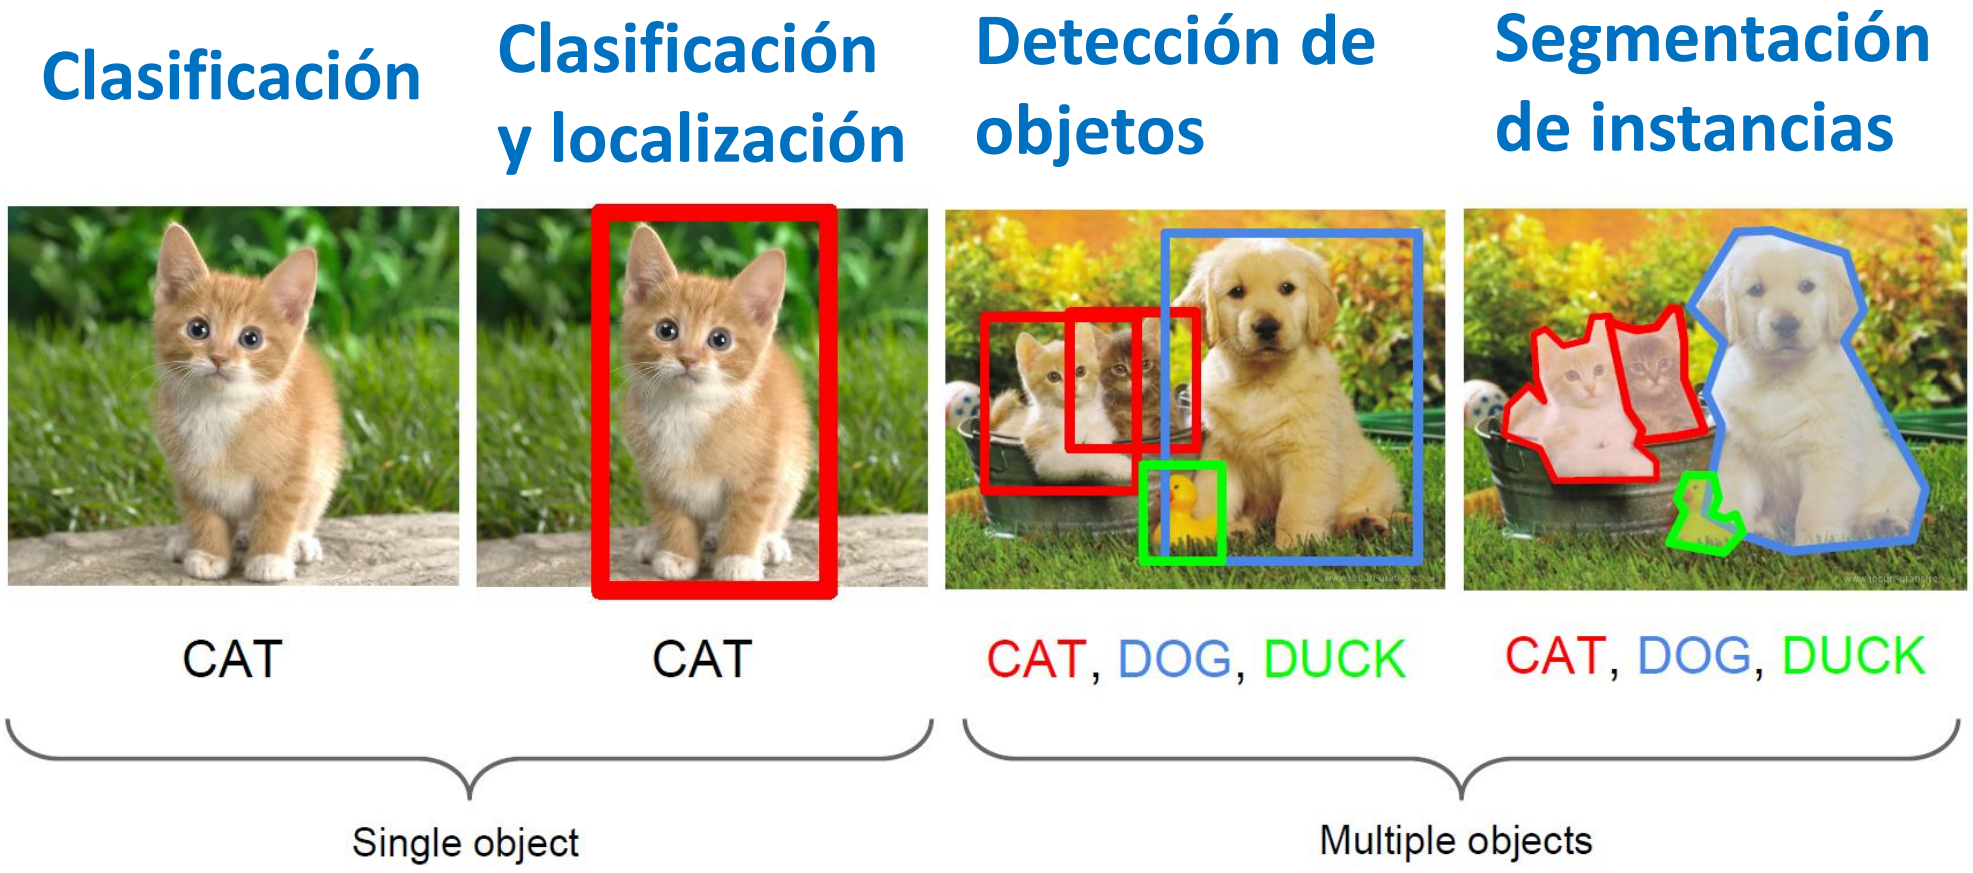

Detección de objetos

Tareas en **visión por computador**

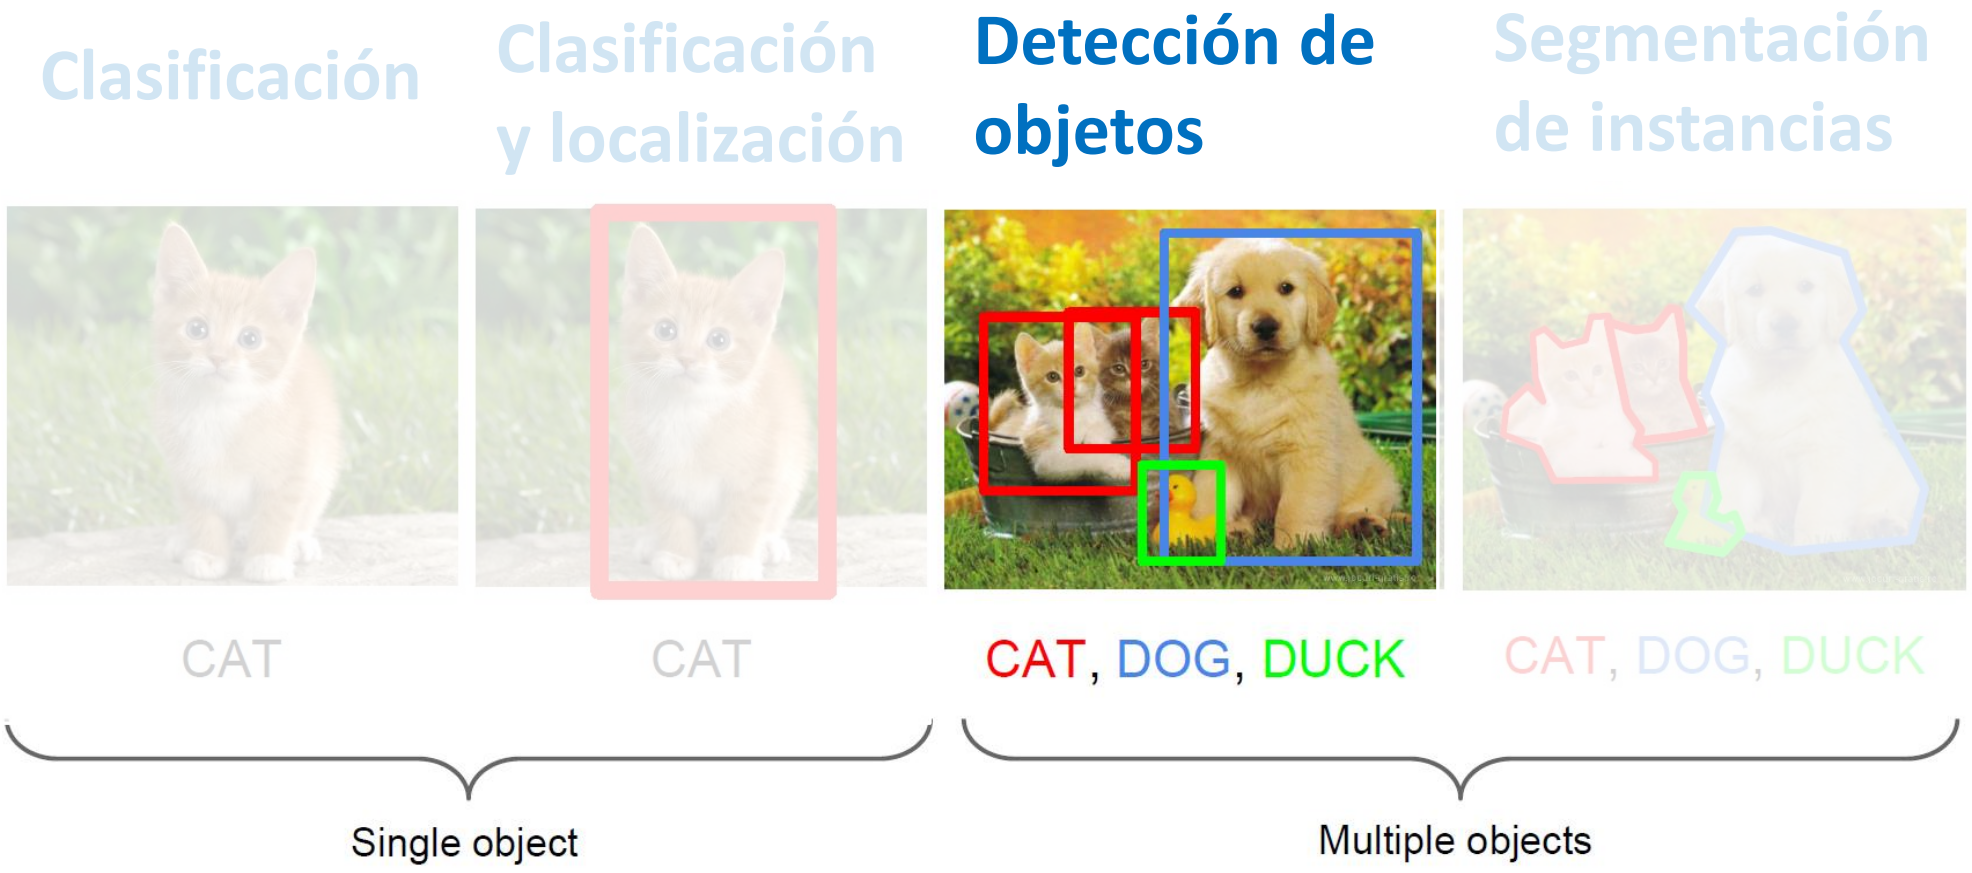

R-CNN

- **R-CNN** (2014): familia de modelos creados en Microsoft Research
- **Fast R-CNN** (2015)
- **Faster R-CNN** (2016)
- **MASK R-CNN** (segmentación de regiones)

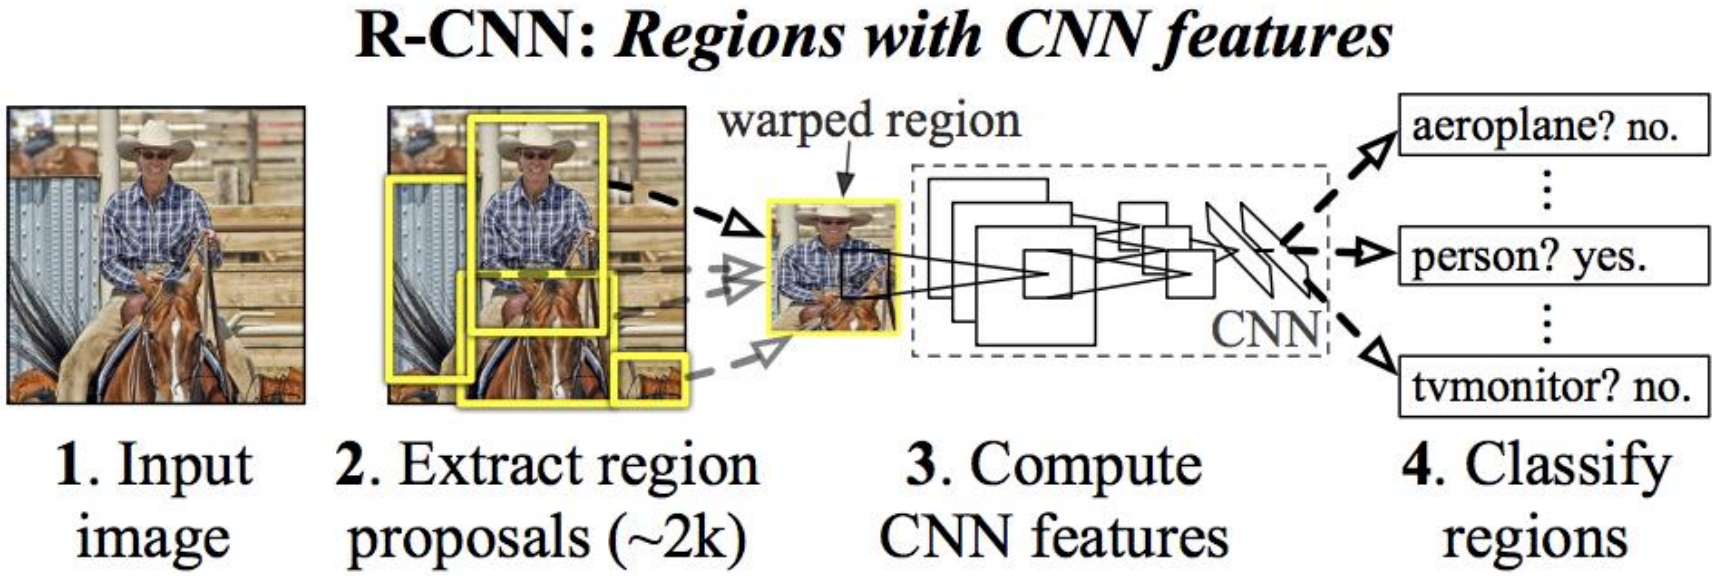

YOLO (*You Only Look Once*, 2015)

- Más rápido que los R-CNN (hasta tiempo real), pero menos preciso
- Infieren los bounding boxes mediante regresión (donde es probable que haya un objeto)

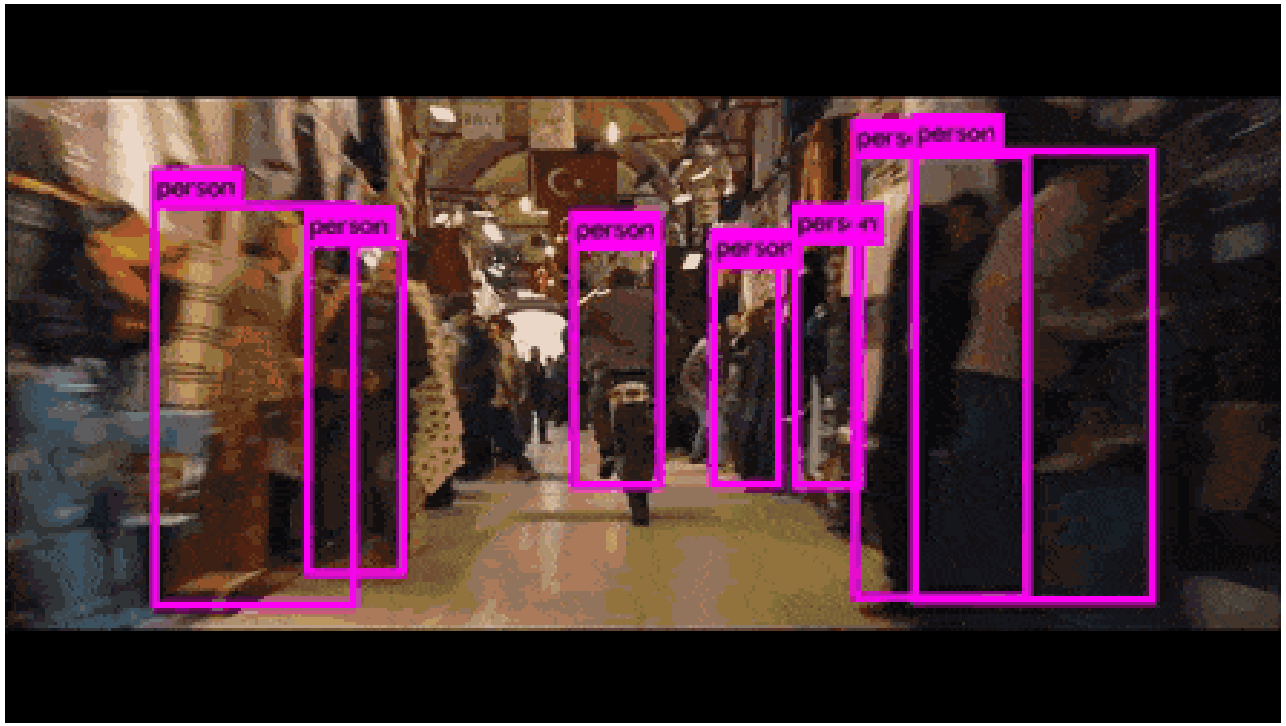

Transfer Learning en Deep Learning

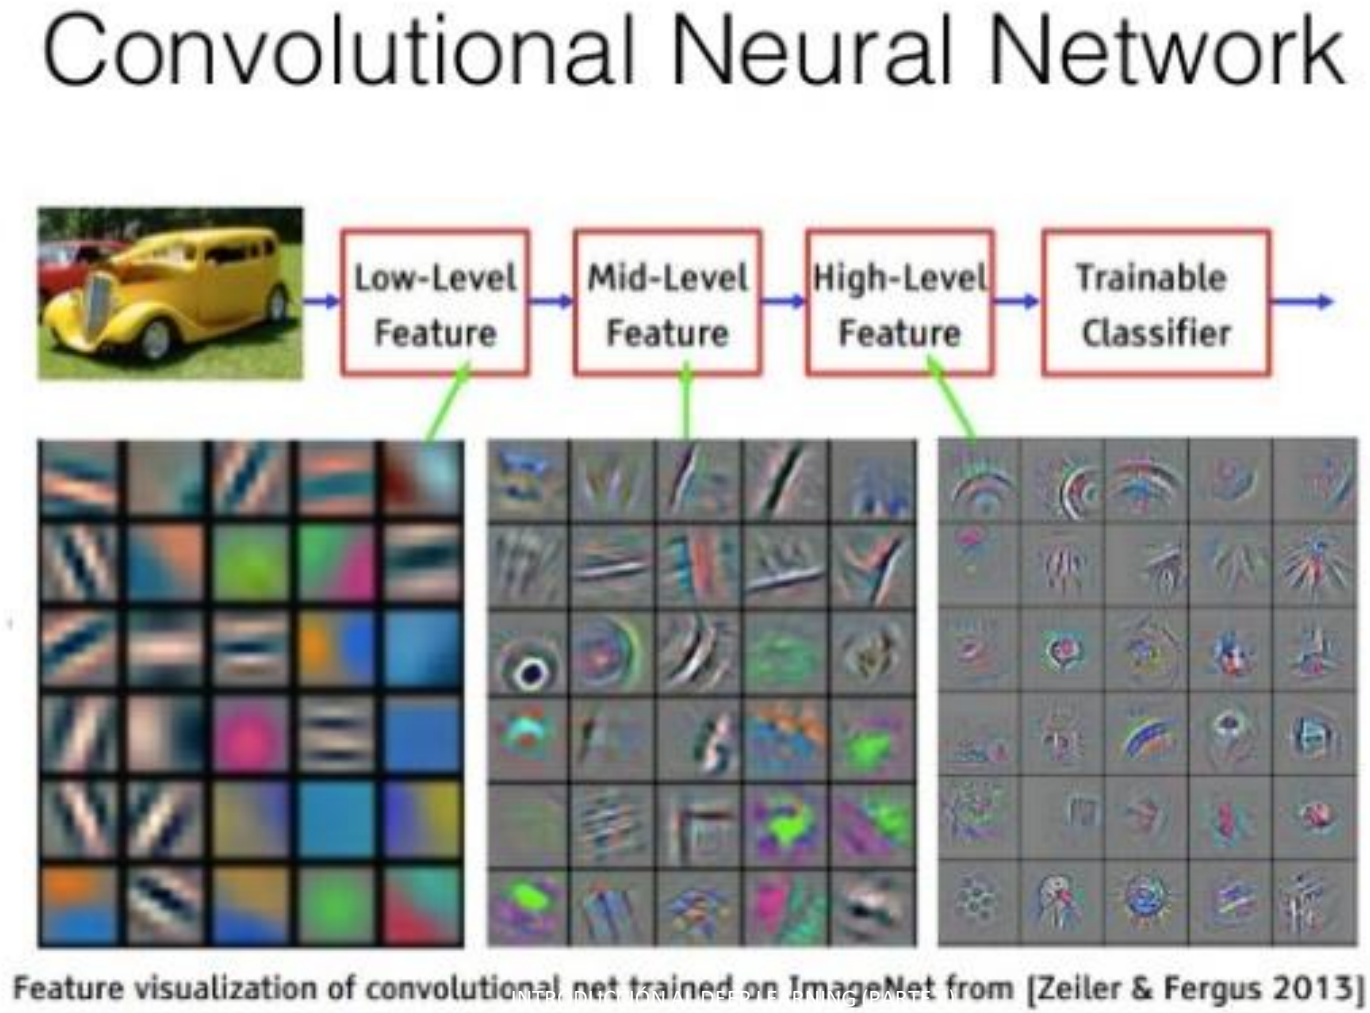

Transfer Learning en Deep Learning

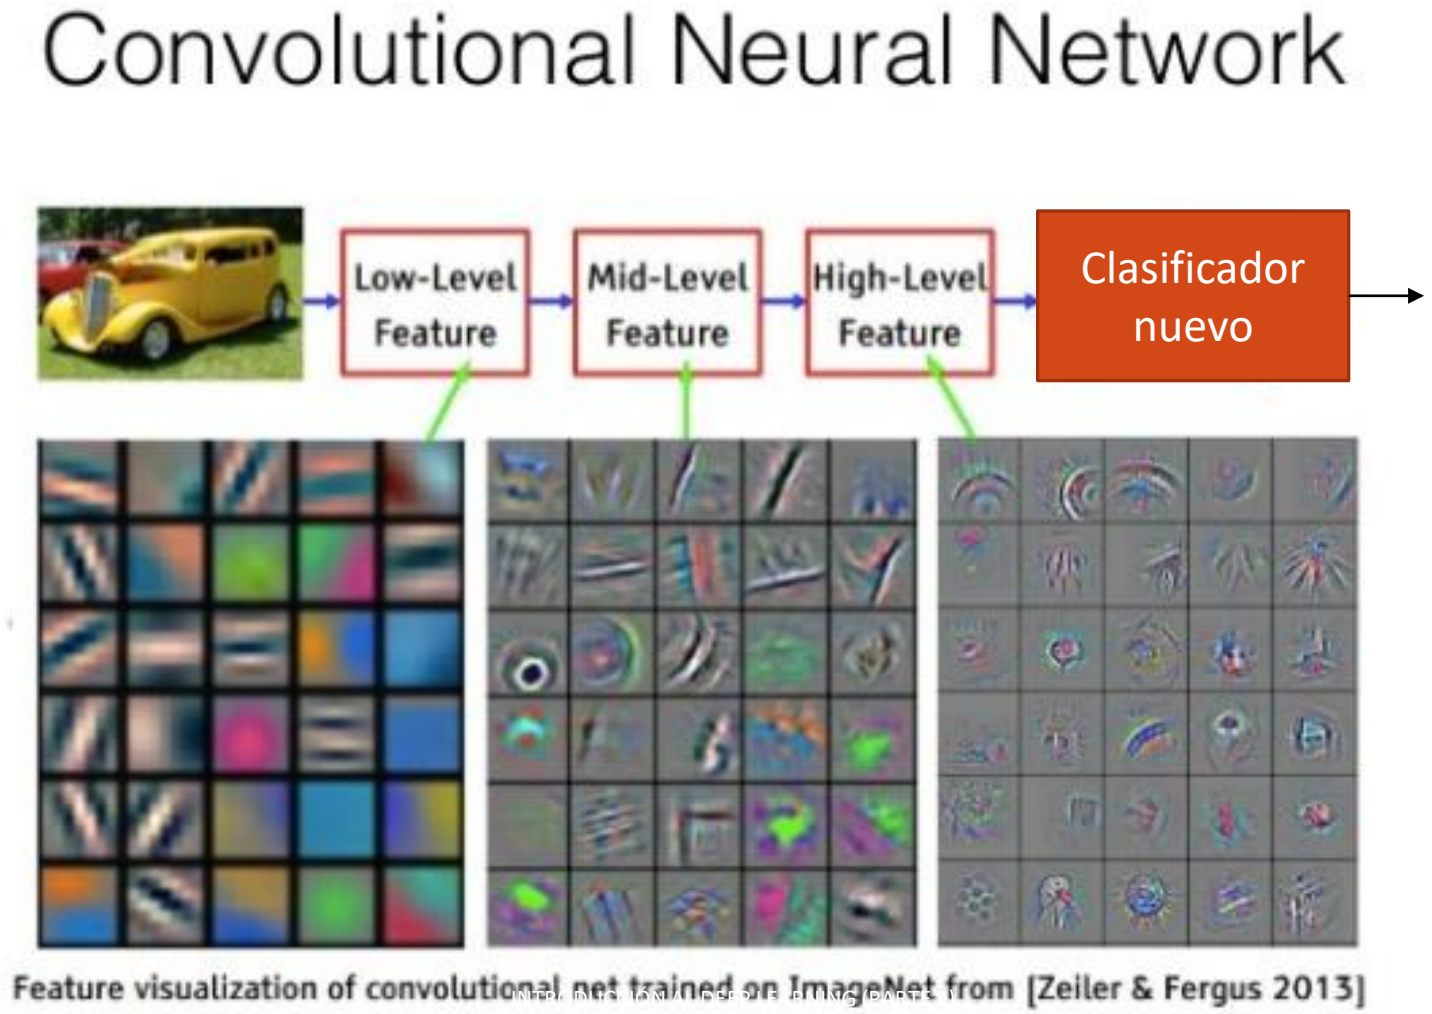

Ejemplo: Tag extraction
(extracción de etiquetas)

Extracción (automática) de etiquetas de películas:

- *Metadatos imprecisos* generado por humanos
- Extracción de *información saliente* usando machine learning
- *Semántica* de "alto nivel"

Idea: selección de etiquetas clave, representando el tema general

Diferente a la mayoría de tareas de reconocimiento de objetos o escenas:

- No nos interesa si en un vídeo aparece una escopeta
- Nos interesa saber si el video es de violencia, acción, etc.

https://doi.org/10.1109/ACCESS.2019.2963535

Ejemplo: Tag extraction
(extracción de etiquetas)

Extracción (automática) de etiquetas de películas:

- *Metadatos imprecisos* generado por humanos
- Extracción de *información saliente* usando machine learning
- *Semántica* de "alto nivel"

Idea: selección de etiquetas clave, representando el tema general

Diferente a la mayoría de tareas de reconocimiento de objetos o escenas:

- No nos interesa si en un vídeo aparece una escopeta
- Nos interesa saber si el video es de violencia, acción, etc.

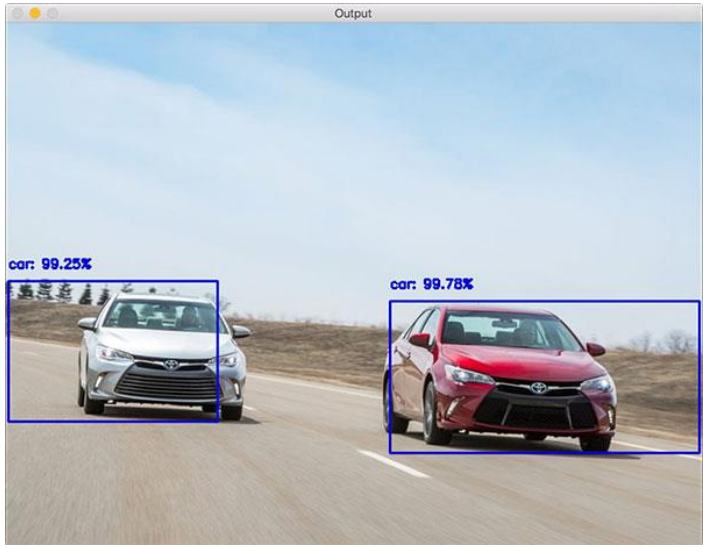

Object detection: 2 cars
vs
Movie tag: car chase

https://doi.org/10.1109/ACCESS.2019.2963535

Ejemplo: Tag extraction
Diseño conceptual

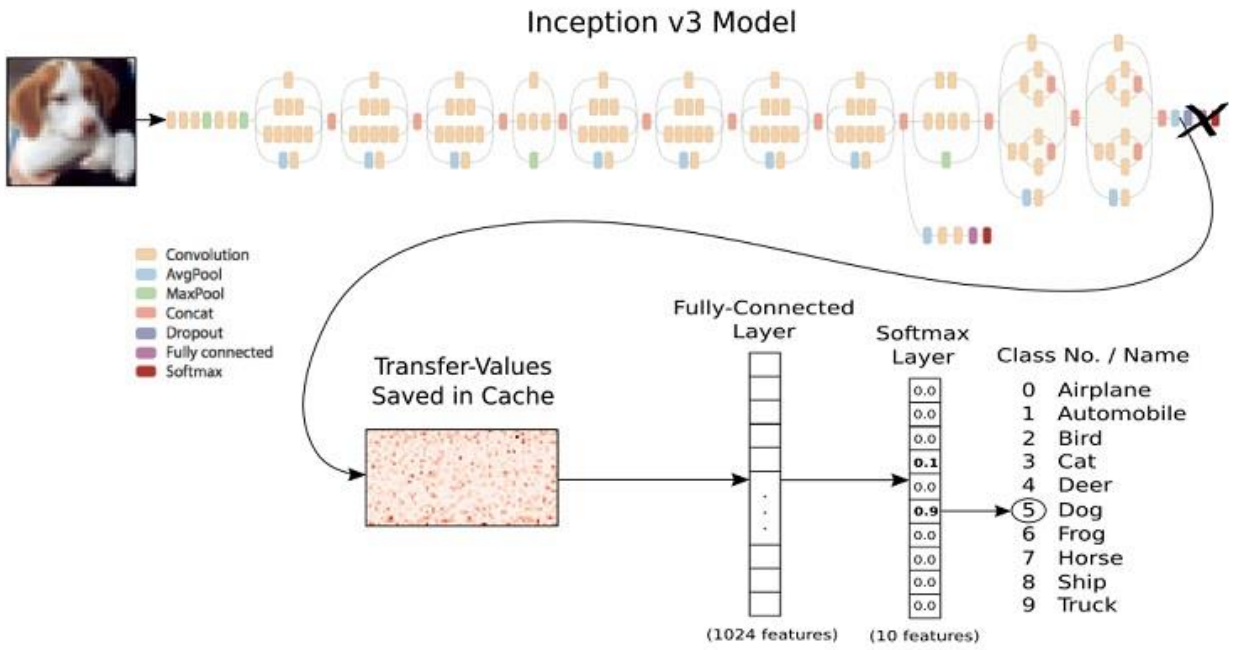

Ejemplo: Tag extraction
Diseño conceptual

Problemática:

- No existe un dataset para etiquetas de películas: confección de uno desde cero y de forma manual
- No disponíamos de recursos computacionales ni de mucho tiempo (beca posdoctoral).

Solución: Transfer Learning

- Necesitamos un dataset “mediano”
- **Inception-v3**:
  - Eliminada última capa
  - Añadida una de Dropout, ReLu y Softmax.

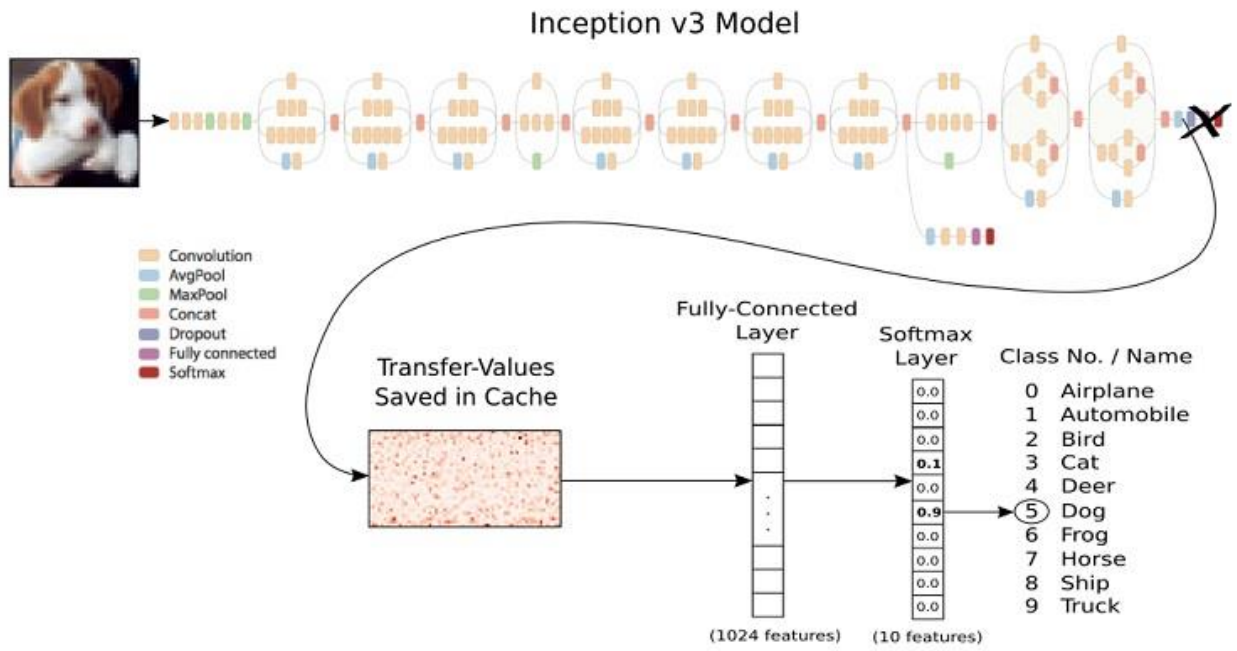

Ejemplo: Tag extraction
Diseño conceptual

Problemática:

- No existe un dataset para etiquetas de películas: confección de uno desde cero y de forma manual
- No disponíamos de recursos computacionales ni de mucho tiempo (beca posdoctoral).

Solución: Transfer Learning

- Necesitamos un dataset “mediano”
- **Inception-v3**:
  - Eliminada última capa
  - Añadida una de Dropout, ReLu y Softmax.

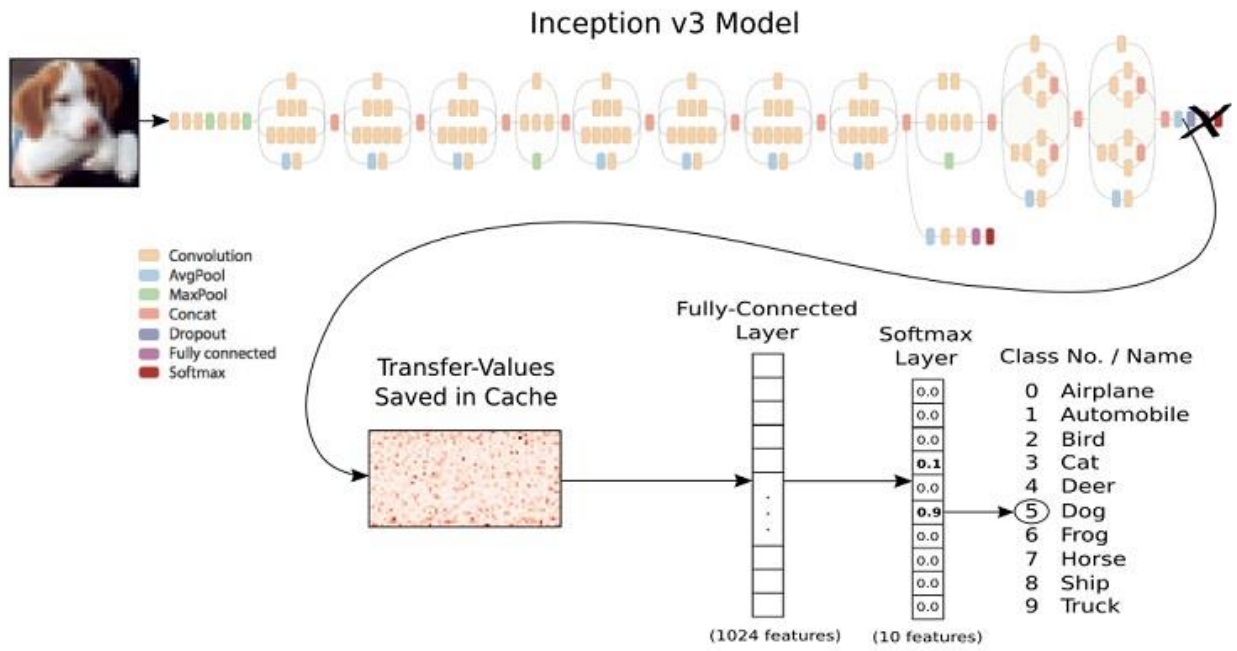

Ejemplo: Tag extraction
Conjunto de datos

- Vocabulario 50 etiquetas (con solapamiento)
- 700 imágenes/etiqueta

Action	Bomb explosion	Car chase
Destruction	Sword fight	Vehicle crash
Violence	Abduction	Heist
Adventure	Animal	Beach/Sea
Climbing	Desert	Hiking
Forest	Valleys/Hills	Children
Family	Club/Bar	Dance
Music	Wedding	College/Univ.
Hospital	Drinking	Food
Smoking	Exercise	Sports
Swimming	Glamor/Fashion	Nudity
Romance	Sex	Horror
Monster	Murder	Lab Experiment
Sci-fi	Super hero	Technology
Robot	Military	Police
Prison	War	Weapon
Animation	Drama	

Ejemplo: Tag extraction

Resultados en fotogramas individuales

Military, action, weapon, war

Violence, destruction, bomb explosion, action, car crash

Sex, nudity, romance, modeling

Hiking, adventure, nature, forest, valleys, hills, climbing

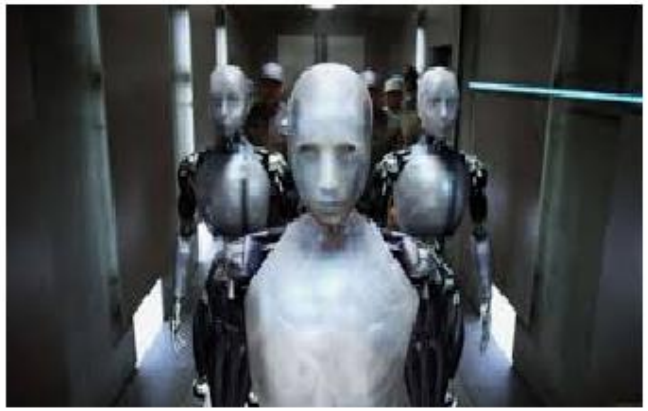

Sci-fi, super hero, robot, action

Violence, sci-fi, action, horror

Índice